

PONTIFICIA UNIVERSIDAD CATÓLICA MADRE Y MAESTRA

CAMPUS SANTIAGO

FACULTAD DE CIENCIAS E INGENIERÍA

ESCUELA DE COMPUTACIÓN Y TELECOMUNICACIONES



**SMART STOCK ANALYZER: OPTIMIZACIÓN DE MANEJO DE
STOCK EN CENTROS DE ACOPIO EN LA REPÚBLICA
DOMINICANA**

SUSTENTADO POR:

Randae Garcia Sanchez 1014-3525

Starlin Frías Luna 1014-3611

PARA OPTAR POR EL TÍTULO DE:

Ingeniería en Ciencias de la Computación

ASESOR:

Ing. Máximo Emiliano Perez Medrano

Abril, 2025

Santiago de los Caballeros, República Dominicana

Tabla de Contenido

Tabla de Contenido	2
Tabla de Imágenes	4
Resumen Ejecutivo	5
Executive Summary	6
Aspectos Introdutorios	7
Antecedentes del Problema	7
Antecedentes del Proyecto	7
Descripción del Problema	9
Planteamiento inicial de la solución	9
Objetivos del Proyecto	10
Objetivo General	10
Objetivo Específicos	10
Justificación del Proyecto	11
Limitaciones del Proyecto	12
Capítulo I - Marco Teórico	15
Introducción	15
1.1. Marco teórico	16
1.1.1. Gestión de Inventarios en Centros de Acopio	16
1.1.2. Visión por Computadora y Reconocimiento de Objetos	19
1.1.3. Aprendizaje Profundo y Detección de Objetos	22
1.1.4. Implementación práctica y consideraciones	25
1.1.5. Procesamiento en la Nube vs. Edge Computing	31
1.2. Definición de Términos y Glosario	34
Capítulo II - Solución Propuesta	38
2.1. Definición del Proyecto	38
2.1.1. Definición	38
2.1.2. Componentes	39
2.1.2.1. Modelo de visión computacional	39
2.1.2.2. Backend en Django	40
2.1.2.3. Aplicación móvil en Flutter	41
2.1.3. Integración de Componentes	41
2.2. Productos del Proyecto	43
2.2.1. Delimitación del alcance	43
2.2.2. Entregables	46
2.2.3. Acuerdo con el Asesor	48
2.3. Cronograma del Proyecto	49
2.3.1. Cronograma de Pre-Proyecto (ISC)	49
2.3.1.1. Primer Entregable - Fecha estimada: 18 de febrero de 2025	49
2.3.1.2. Segundo Entregable - Fecha estimada: 18 de marzo de 2025	51
2.3.1.3. Tercer Entregable - Fecha estimada: 8 de abril de 2025	52
2.3.2. Cronograma de Proyecto Final (ISC)	53

2.3.2.1. Cuarto Entregable - Fecha estimada: 31 de mayo de 2025.....	53
2.3.2.2. Quinto Entregable - Fecha estimada: 28 de junio de 2025.....	55
2.3.2.3. Sexto Entregable - Fecha estimada: 25 de julio de 2025.....	56
2.4. Plan de Administración de Riesgos.....	58
2.4.1. Enfoque metodológico para la evaluación de riesgos.....	58
2.4.2. Matriz de Riesgos y Planes de Respuesta.....	59
2.4.2.1. Matriz de Riesgos.....	59
2.4.2.2. Planes de Acción y Puntos de Activación.....	60
2.4.3. Estrategias Para el Manejo de Riesgos.....	62
2.5. Presupuesto.....	64
2.6. Definición de la demostración.....	65
2.6.1. Lugar.....	65
2.6.2. Escenario.....	65
2.6.3. Materiales necesarios.....	66
2.6.4. Condiciones de prueba.....	66
2.6.5. Escenario de respaldo.....	67
2.7. Análisis y Diseño.....	68
2.7.1. Análisis.....	68
2.7.2. Diseño.....	71
Análisis de resultados obtenidos en la primera etapa.....	77
Referencias.....	82

Tabla de Imágenes

Diseño general del sistema.....	39
Tabla de Presupuesto del proyecto.....	64
Mapa Conceptual.....	69
Diagrama de procesos.....	71
Diagrama de casos de uso.....	71
Diseño de ambiente de usuario (Mockups):.....	73
Diagramas de clase.....	75
Modelo de datos.....	76
Diagrama de despliegue.....	76
Diagrama de secuencia.....	76
Imagen de prueba para condiciones óptimas.....	79
Imagen de prueba para condiciones no óptimas.....	81

Resumen Ejecutivo:

Los centros de acopio en la República Dominicana enfrentan importantes desafíos en la gestión de inventario de productos no perecederos. La ausencia de software especializado para automatización resulta en procesos altamente manuales, generando planificaciones erróneas y desperdicio de recursos críticos, situación que se agrava durante emergencias donde una distribución óptima de productos es vital.

Como solución, se propone una innovadora aplicación móvil que emplea visión computacional para optimizar la gestión mediante capturas de imágenes en áreas de almacenamiento con la cámara del dispositivo móvil. El sistema puede identificar y contabilizar siete categorías de productos: bebidas, lácteos, cereales, alimentos enlatados, galletas, pastas y condimentos.

La implementación utiliza una arquitectura híbrida que combina procesamiento local y en la nube mediante infraestructura desplegada en Droplets de DigitalOcean. Para la identificación de clases, se emplean modelos pre-entrenados de YOLO en diferentes versiones como YOLOv8, YOLOv8x, YOLOv5, siendo YOLOv8 el que ha proporcionado mejores resultados con una precisión entre 60-90% según la clase.

El dataset base proviene de Open Food Facts, refinado mediante imágenes sintéticas para adaptarlo al contexto específico de los centros de acopio. Hasta el momento, las pruebas realizadas indican que el rendimiento del modelo disminuye en entornos con iluminación no controlada o productos apilados con poca visibilidad. Las condiciones óptimas actuales requieren una iluminación entre 300-800 lux, con separación entre productos de 3-5 cm y una distancia de captura de imagen de 50-120 cm.

Executive Summary

Collection centers in the Dominican Republic face significant challenges in managing non-perishable product inventory. The absence of specialized software for automation results in highly manual processes, generating erroneous planning and waste of critical resources, a situation that worsens during emergencies where optimal distribution of products is vital.

As a solution, an innovative mobile application is proposed that uses computer vision to optimize management through image captures in storage areas with the mobile device's camera. The system can identify and count seven product categories: beverages, dairy products, cereals, canned foods, cookies, pasta, and condiments.

The implementation uses a hybrid architecture that combines local and cloud processing through infrastructure deployed on DigitalOcean Droplets. For class identification, pre-trained YOLO models are used in different versions such as Yolov8, Yolov8x, Yolov5, with Yolov8 providing the best results with an accuracy between 60-90% depending on the class.

The base dataset comes from Open Food Facts, refined through synthetic images to adapt it to the specific context of collection centers. So far, tests indicate that the model's performance decreases in environments with uncontrolled lighting or stacked products with poor visibility. The current optimal conditions require lighting between 300-800 lux, with separation between products of 3-5 cm and an image capture distance of 50-120 cm.

Aspectos Introductorios

Antecedentes del Problema

Este proyecto irá dirigido a los centros de acopio en la República Dominicana, los cuales desempeñan un papel fundamental en situaciones de emergencias. En estas situaciones se debe actuar de forma eficiente y precisa, pero estos centros presentan problemáticas con la gestión de los productos no perecederos. La ausencia de un sistema de automatización dificulta la planificación en la cual se distribuyen estos productos, sin mencionar el desperdicio descontrolado de los mismos.

En la República Dominicana, normalmente estos centros de acopio son gestionados de forma manual, lo que dificulta bastante la eficiencia, como la precisión con respecto a los productos disponibles en tiempo real. En los tiempos de emergencia cuando azotan huracanes, inundaciones y terremotos, operar manualmente genera errores humanos debido a la desesperación y falta de tiempo disponible, todo esto genera caos y desorden sin contribuir a un uso adecuado de los productos no perecederos disponibles.

Actualmente, lugares como estos centros no cuentan con la tecnología, infraestructura ni el personal especializado para llevar a cabo una implementación de gestión de inventario sofisticada.

Antecedentes del Proyecto

Tanto a nivel internacional como nacional, existen grandes cantidades de sistemas con innovaciones para gestión de inventarios. No obstante, pocas están dirigidas específicamente a los centros de acopios o escenarios de emergencias como el enfoque que busca Smart Stock Analyzer: Optimización de Manejo de Stock en Centros de Acopio en la República Dominicana.

Entre los proyectos similares se destacan los siguientes:

1. **Identificación de artículos fuera de stock en tiendas minoristas mediante visión computacional:** Proyectos como el descrito en [\[1\]](#), llamado “Identifying Out-of-stock

Items at Retail Stores Using Computer Vision: Extended Abstract”, donde hacen uso de visión computacional para captura la disponibilidad de productos en tiempo real.

2. **Detección de objetos en la imagen de la estantería de la tienda minorista utilizando un detector de una sola etapa:** Como el proyecto [\[2\]](#), nombrado “Object Detection in Shelf Image of the Retail store using Single Stage Detector” (2024), donde hacen uso del modelo YOLOv5, con el objetivo el conteo preciso de artículos y la categorización de productos mediante la detección de clases.
3. **Diseño y evaluación de un sistema de gestión de inventario de stock en tiempo real:** [\[3\]](#) “Design and Evaluation of a Real-Time Stock Inventory Management System” (2023), combina modelos y técnicas como son You Only Look Once (YOLO), Single Shot Detector (SSD) y Faster Region-based Convolutional Neural Network (Faster-RCNN), y su objetivo es la identificación de objetos en inventarios de hospitales, tiendas, laboratorios, etc.

Descripción del Problema:

Los centros de acopio en la República Dominicana presentan las siguientes problemáticas:

1. **Ineficiencia en la contabilización e identificación de los productos:** Actualmente estos procesos son realizados manualmente. Se completan lentamente y son propensos a errores humanos.
2. **Complejidad de llevar actualizado el inventario:** La ausencia de un sistema automatizado dificulta un seguimiento en tiempo real de los productos disponibles.
3. **Dificultad de seguimiento de consumo:** Cuando no se cuenta con datos exactos con respecto al consumo de productos, es difícil prever las posibles necesidades futuras para mejorar la disponibilidad en caso de otras emergencias que puedan surgir.
4. **Ineficiente distribución en emergencias:** En los eventos de crisis, cuando sucede una situación de emergencia, la falta precisa con respecto a la información del inventario obstaculiza la rápida respuesta del personal de ayuda.
5. **Barrera presupuestaria y tecnología:** Normalmente los centros de acopios en el contexto local de la República Dominicana no cuentan con una gran capacidad financiera. Por tanto, se dificulta la implementación de soluciones comerciales avanzadas.

Planteamiento inicial de la solución:

El proyecto Smart Stock Analyzer tiene como objetivo implementar una alternativa móvil accesible y altamente capaz de una gestión automatizada del inventario para los productos no perecederos en los centros de acopio dominicanos.

La solución se enfoca en otorgar a los operadores de estos centros una aplicación móvil con la que capturen imágenes del inventario encontrado en sus almacenes. La aplicación permitirá analizar las imágenes tomadas donde identificará, clasificará y contará de forma automática los diferentes productos que se encuentren en el área.

A partir de este reconocimiento visual, la aplicación creará un inventario base digitalizado que servirá como punto de referencia. Posteriormente, mediante la captura periódica de

nuevas imágenes, el sistema detectará cambios en el inventario, generando alertas sobre productos que necesitan reposición y proporcionando información estadística sobre patrones de consumo.

La solución incluirá funcionalidades para que los usuarios clasifiquen y etiqueten productos, facilitando consultas por categorías específicas en situaciones de emergencia. También permitirá ajustes manuales cuando sea necesario, combinando así la eficiencia de la automatización con la flexibilidad del control humano.

Esta propuesta busca proporcionar una alternativa económica, rápida y accesible que no requiere equipamiento especializado ni personal técnico dedicado, adaptándose a las realidades operativas y presupuestarias de los centros de acopio dominicanos.

Objetivos del Proyecto

Objetivo General

Desarrollar un sistema basado en visión computacional que brinde una mejora asequible en la automatización y optimización en la gestión de inventarios de productos no perecederos en centros de acopio en la República Dominicana.

Objetivo Específicos

1. Desarrollar un modelo de reconocimiento visual con la capacidad de identificar y cuantificar en áreas de almacén productos no perecederos comunes (alimentos enlatados, leche en polvo, galletas, agua embotellada) mediante las imágenes tomadas a través de los dispositivos móviles, con la expectativa de obtener una precisión mínima de un 85%.
2. Permitir la gestión del inventario con el desarrollo de una aplicación móvil intuitiva e integrada con el modelo de reconocimiento. Esta enviará alertas sobre los niveles críticos de productos y generará reportes de consumo.
3. Implementar un sistema de etiquetado y clasificación para facilitar consultas del inventario, permitiendo realizar búsquedas por categorías específicas para garantizar el acceso rápido a los productos críticos en momentos de emergencia.

4. Validar la efectividad de la solución planteada en escenarios apropiados mediante pruebas exhaustivas para evaluar su impacto en la eficiencia y la capacidad de respuesta.

Justificación del Proyecto

El proyecto Smart Stock Analyzer responde a una necesidad crítica en el contexto dominicano, ofreciendo múltiples beneficios que justifican su desarrollo:

Conveniencia: La solución que proporciona el proyecto está adaptada específicamente a las características y limitaciones de gestión de inventarios en los centros de acopio dominicanos. Actualmente estos centros realizan sus operaciones manualmente y carecen de herramientas accesibles que brinden una gestión óptima del inventario. Es por esto que la iniciativa implementada por el proyecto simplificará la gestión mediante un aplicativo móvil, permitiendo una mejora sustancial en su operatividad diaria.

Relevancia social: Esta solución beneficiará a los centros de acopio y a las comunidades que reciben apoyo de estos durante situaciones de emergencia.

Implicaciones prácticas: Los problemas planteados dificultan el control preciso del inventario sin requerir de un gran personal o recursos humanos. La solución a implementar removerá la necesidad de un personal técnico dedicado, lo cual permitirá adaptarse a las restricciones presupuestarias típicas en estos centros.

Valor teórico: En cuestiones de técnicas avanzadas de visión computacional, el proyecto aporta aplicaciones prácticas en un contexto específico, además de considerar las restricciones reales. Este proyecto genera conocimientos relacionados a la adaptación tecnológica en entornos con recursos limitados, por lo que podrían escalar o extrapolarse a otros ámbitos similares, no solo en la República Dominicana, sino en otros países con desafíos comparables.

Utilidad metodológica: El diseño del modelo para permitir el reconocimiento visual de los productos no perecederos de forma específica del mercado dominicano permitirá desarrollar otros más capaces, lo cual ayudaría en aspectos de desarrollo del país y futuros proyectos de investigación donde se requieran gestiones de inventarios y enfoques en este rubro.

Limitaciones del Proyecto

El proyecto Smart Stock Analyzer contempla las siguientes limitaciones:

1. **Precisión del reconocimiento del modelo en ciertos escenarios:** El modelo entrenado puede tener complicaciones en algunas circunstancias o escenarios donde los productos estén amontonados, sean pocos visibles o cuando la iluminación sea deficiente. Cabe mencionar que la calidad de la cámara del dispositivo podría afectar negativamente a los resultados. Esto se debe a que una mayor calidad de imagen proporciona una mejor visión de los productos permitiendo al modelo extraer los datos con mayor precisión.
2. **Alcance de los productos reconocibles:** El enfoque de detección y predicción de los productos no perecederos estará limitado a las siguientes categorías:
 - a. beverage (Para las bebidas)
 - b. dairy (Leches en polvos, y demás)
 - c. cereal (Cereales)
 - d. canned_food (Alimentos enlatados)
 - e. crackers_cookies (Galletas)
 - f. pasta_noodles (Espaguetis, y demás)
 - g. condiments
3. **Dependencia de conexión a internet:** Para aprovechar el uso de todas las funcionalidades del sistema, es necesario contar con una conexión a internet. La comunicación existente entre los distintos componentes del sistema, algunos alojados en la nube, hace que la necesidad de una conexión wifi sea imperativa.
4. **Aspectos fuera del alcance:** Smart Stock Analyzer no contempla los siguientes aspectos:

- a. **Detección de marcas específicas por producto:** La solución se centrará en la clasificación e identificación de los productos no perecederos por categorías generales sin diferenciar entre marcas.
 - b. **Predicción precisa de demanda futura:** El sistema proporcionará estadísticas básicas de consumo de los productos, pero no hará inclusión de algoritmos avanzados para predecir la demanda de los mismos basados en factores externos.
 - c. **Gestión logística de transporte y distribución:** La implementación no gestionará la logística de la distribución o las rutas de entregas, sino que solo brinda facilidad para la gestión de inventario en el centro de acopio.
 - d. **Reconocimiento de productos dañados o en mal estado:** El modelo permitirá identificar la presencia de los productos, pero no hará una evaluación de sus estados como su conservación o integridad.
 - e. **Reconocimiento de texto (OCR) para lectura detallada de etiquetas:** La solución permite identificar los productos mediante las características y aspectos visuales de los objetos, no a través de la lectura detallada de texto en las etiquetas.
 - f. **Sophorte para múltiples idiomas en la interfaz:** La interfaz sólo se encontrará disponible en español porque está orientada a los centros de acopio de la República Dominicana.
5. **Disponibilidad de datos de entrenamiento:** La precisión del modelo dependerá de la calidad del dataset con el que se entrena. Es necesario mencionar que existen algunas limitaciones relacionadas a las imágenes de productos específicos de la República Dominicana, además, los centros de acopio no siempre se encuentran operando para permitirnos la creación de un dataset propio, por lo que existirá confusión entre ciertos productos.
6. **Condiciones de iluminación controlada:** El modelo será diseñado para obtener su máximo rendimiento cuando el almacén cuente con una iluminación controlada entre 300-800 lux (equivalente a la iluminación estándar de oficinas y espacios

comerciales). En ambientes donde la luz es inferior a 200 lux, o superior a 1000 lux, la precisión del modelo en la detección se podría ver reducida por debajo de un 75%. Lo ideal es mantener el rango expuesto anteriormente, evitar las posibles sombras pronunciadas y los reflejos entre productos. Para conseguir los mejores resultados se recomienda la luz blanca (temperatura de color entre 4000k-5000k).

7. **Disposición específica de productos para análisis masivo:** La separación mínima entre los productos debe ser de al menos 1 cm entre ellos y una distancia de captura óptima de 50-120 cm para obtener los mejores resultados posibles. La cámara debe estar entre un ángulo de 70-90 grados con respecto a la superficie donde se encuentran ubicados los productos. La detección de productos apilados con superposición mayor al 30%, o donde menos del 60% de la etiqueta principal sea visible, tendrá una precisión reducida. Se recomienda organizar los productos en filas con no más de 8-10 unidades por grupo de captura para obtener resultados óptimos.

Capítulo I - Marco Teórico

Introducción:

En el presente marco teórico siguiente se establecen las bases tanto conceptuales como tecnológicas del proyecto en cuestión llamado Smart Stock Analyzer, la cual consiste en la solución para permitir la gestión de inventarios para centros de acopio en la República Dominicana mediante el uso de técnicas de visión por computadora y aprendizaje automático. El objetivo de este capítulo es proporcionar una comprensión integral de los fundamentos teóricos, las tecnologías disponibles, avances recientes y los desafíos actuales en el campo de la gestión automatizada para inventarios mediante el uso de modelos de visión computacional.

La gestión eficiente de los inventarios es un pilar fundamental para las operaciones de forma exitosa en los centros de acopio, especialmente en estos contextos debido a que los recursos son limitados y la capacidad de respuesta instantánea y rápida es crucial, como los escenarios durante situaciones de emergencia. El objetivo y enfoque de la solución planteada en el proyecto de Smart Stock Analyzer no busca reemplazar la forma tradicional de gestionar estos, sino facilitar y brindar mayor automatización mediante la visión por computadora. Las técnicas tradicionales son ampliamente establecidas, pero presentan sus respectivas limitaciones en aspectos de eficiencia y requerimiento de personal.

En este contexto, las tecnologías emergentes de visión por computadora actualmente conocidas y aprendizaje automático ofrecen oportunidades prometedoras para revolucionar la forma en que se gestionan los inventarios. Estas tecnologías permiten automatizar procesos que tradicionalmente han requerido intervención humana intensiva, como el conteo, la identificación y la clasificación de productos de forma manual.

Este marco teórico brinda y explora cuál ha sido la evolución que han tenido los sistemas tradicionales de gestión de inventario a través del tiempo, desde métodos manuales hasta las soluciones basadas en aspectos de inteligencia artificial. Además, permite analizar las ventajas, limitaciones y la aplicabilidad en el contexto de los centros de acopio dominicanos específicamente. Asimismo, en profundidad se realiza una examinación de las técnicas de visión por computadora y aprendizaje profundo que constituyen la base tecnológica del proyecto, con mayor enfoque en los algoritmos y reconocimiento de los objetos.

También se abordan cuáles son esos desafíos particulares que se presentan en los entornos donde hay restricciones tecnológicas, como conectividad limitada, recursos computacionales restringidos y las necesidades específicas de usuarios sin formación técnica avanzada. Además, también se exploran cuáles son las tendencias actuales, como las futuras en la aplicación de estas tecnologías en contextos similares alrededor del mundo.

En general este marco teórico no sólo proporciona los fundamentos necesarios para comprender el desarrollo técnico del proyecto en cuestión Smart Stock Analyzer, sino que también contextualiza su relevancia en el panorama más amplio de la transformación digital en operaciones logísticas y humanitarias, destacando cómo tales innovaciones pueden contribuir significativamente a mejorar la eficiencia operativa y la capacidad de respuesta en situaciones críticas.

1.1. Marco teórico

1.1.1. Gestión de Inventarios en Centros de Acopio

La gestión de inventarios constituye una disciplina fundamental dentro de la administración de operaciones que se ocupa de la planificación, control y verificación de los materiales almacenados en una organización. En el contexto específico de los centros de acopio, especialmente aquellos dedicados a la ayuda humanitaria o preparación para emergencias, esta gestión adquiere características particulares debido a la naturaleza de los productos manejados y las circunstancias en que operan (Balcik et al., 2020) [\[4\]](#).

Los centros de acopio se definen como instalaciones logísticas destinadas a la recepción, clasificación, almacenamiento y distribución de bienes, generalmente con fines humanitarios o de respuesta a emergencias. A diferencia de los almacenes comerciales, estos centros suelen operar con recursos limitados, enfrentar fluctuaciones impredecibles en la oferta y demanda, y manejar una diversidad de productos donados o adquiridos específicamente para situaciones de crisis (Van Wassenhove, 2019) [\[5\]](#).

La gestión de inventarios en estos centros presenta desafíos únicos como:

Variabilidad e incertidumbre: La imprevisibilidad de las situaciones de emergencia genera patrones de demanda altamente variables y difíciles de pronosticar (Çelik et al., 2012) [\[6\]](#).

Criticidad de los productos: A diferencia de entornos comerciales, donde el objetivo principal es la rentabilidad, en los centros de acopio humanitarios la disponibilidad de ciertos productos puede ser cuestión de vida o muerte (Van Wassenhove, 2006) [\[7\]](#).

Rotación irregular: Algunos productos pueden permanecer almacenados durante largos períodos hasta que ocurra una emergencia, mientras que otros pueden tener una alta rotación incluso en períodos normales (Tomasini & Van Wassenhove, 2009) [\[8\]](#).

Limitaciones de recursos: Los centros de acopio suelen operar con restricciones presupuestarias y de personal que limitan su capacidad para implementar sistemas sofisticados de gestión (Holguín-Veras et al., 2012) [\[9\]](#).

Cuando nos referimos a los modelos tradicionales en las gestiones de inventarios debemos tener en cuenta que estos incluyen:

Modelo de Cantidad Económica de Pedido (EOQ): Este modelo se enfoca en determinar la cantidad óptima de los productos a pedir para lograr minimizar los costos de mantenimiento y realización de los pedidos (Harris, 1913; Wilson, 1934) [\[10\]](#). No obstante, este modelo asume que la demanda será constante, lo que rara vez sucede en los centros de acopios humanitarios en la República Dominicana.

Sistemas de Revisión Continua y Periódica: En estos sistemas se realizan monitoreos constantemente con el objetivo de medir los niveles de inventarios (revisión continua) o del mismo modo realizan verificaciones en intervalos fijos (revisión periódica) para determinar cuándo debe reponer las existencias de los productos (Silver et al., 2016) [\[11\]](#).

Modelos de Inventario para Ítems Perecederos: El enfoque que proporcionan es considerando la vida útil limitada de ciertos productos, de cierto modo es relevante para algunos casos de suministros humanitarios (Nahmias, 1982; Karaesmen et al., 2011) [\[12\]](#).

En el ámbito de la República Dominicana, estudios recientes han señalado que en general los centros de acopio hacen uso de métodos manuales o semi-automatizados para la gestión de inventarios, lo que resulta en:

- **Inexactitudes en los registros de inventario:** Acorde a un estudio en microempresas de alimentos concentrados comprobó, además, de evidenciar diferencias significativas entre los registros en el inventario que se hacían y la realidad física con lo que se contaba, atribuidas al uso de hojas de cálculos y procedimientos empíricos [\[13\]](#).
- **Tiempos excesivos dedicados a actividades de conteo y verificación:** En el ámbito de la República Dominicana, actualmente no se dispone de datos específicos, pero investigaciones con respecto en otros contextos señalan que los procesos manuales de inventario llegan a consumir hasta un 30% del tiempo del personal en general, de modo que afecta la productividad [\[14\]](#).
- **Dificultades para identificar necesidades de reposición oportunamente:** No es un misterio que la falta de implementación de sistemas automatizados genera dificultad para la detección y monitoreo de niveles en bajos de stock, lo que provoca desabastecimientos o exceso de inventario en muchos casos.
- **Distribución subóptima durante situaciones de emergencia:** La ausencia de los registros precisos y en todos momentos actualizados limita la realización de una respuesta óptima y eficiente ante demandas urgentes, comprometiendo la capacidad de reacción adecuada durante situaciones críticas y de emergencias.

Las soluciones y sistemas automatizados que permitan una gestión de inventarios en muchos casos podrían disminuir estos problemas planteados, mejorando la precisión de los registros y brindando una mejora significativa en los procesos operativos.

1.1.2. Visión por Computadora y Reconocimiento de Objetos:

El tópico conocido como visión por computadora es una rama o disciplina dentro de la inteligencia artificial la cual tiene como objetivo buscar dotar a las máquinas con la capacidad de “ver” y comprender el contenido visual de manera similar a como lo hacen los humanos. Esta se ha desarrollado rápidamente en las últimas décadas, logrando una evolución desde técnicas básicas de procesamiento de imágenes hasta implementaciones sofisticadas en reconocimiento basados en aprendizaje profundo (Szeliski, 2022) [\[15\]](#).

El reconocimiento de objetos es una de las tareas fundamentales dentro de la visión por computadora, esta se refiere a la identificación, además, la localización de ciertas entidades específicas en las imágenes o videos. La capacidad que nos permite la visión por computadora es esencial para el proyecto Smart Analyzer, ya que permite el conteo e identificación automática de los productos no perecederos dentro de los centros de acopios.

Evolución de las técnicas de reconocimiento de objetos:

1. Métodos basados en características manuales (1990s-2000s):

- Histogramas de Gradientes Orientados (HOG): Desarrollados por Dalal y Triggs (2005), son descriptores los cuales permiten capturar la distribución de gradientes de intensidad y orientación de bordes [\[16\]](#).
- Scale-Invariant Feature Transform (SIFT): Propuesto por Lowe (1999), no es más ni menos que un algoritmo el cual brinda la capacidad de identificar y, además, describe cuales son los aspectos y características locales en imágenes, es bastante robusto ante cambios de escala, rotación e iluminación [\[17\]](#).
- Speeded-Up Robust Features (SURF): Presentado por Bay et al. (2006), es un método el cual logra un mejor rendimiento mas optimo en aspectos computacional que el de SIFT mientras también mantiene un nivel similar de robustez [\[18\]](#).

Estos métodos de cierto modo son innovadores para sus épocas, pero estaban limitados en escenarios como entornos complejos, además, de que requieren considerar muchos aspectos en el diseño manual de características.

2. Métodos basados en aprendizaje automático clásico (2000s-2010s):

- Support Vector Machines (SVM): Estos son en su mayoría utilizados en combinación con descriptores HOG o SIFT con el objetivo de permitir la clasificación de objetos en imágenes (Cortes & Vapnik, 1995) [\[19\]](#).
- Bag of Visual Words: Adaptación del modelo "bag of words" de procesamiento de lenguaje natural para la visión por computadora, con la capacidad de lidiar con aspectos como "palabras" mediante una imagen o video (Csurka et al., 2004) [\[20\]](#).
- Random Forests: Estos son conjuntos de árboles de decisión los cuales son usados y empleados para clasificación y localización de objetos (Breiman, 2001) [\[21\]](#).

No es un misterio que estos métodos mejoraron los resultados en muchos aspectos, pero seguían dependiendo en su mayoría de características diseñadas manualmente y presentaban dificultades en aspectos de variaciones complejas.

3. Métodos basados en aprendizaje profundo (2012-presente):

- Redes Neuronales Convolucionales (CNN): En general lo que inspiraron estas redes fue el cortex visual de los mamíferos, lo que permitieron que estas redes revolucionaran fue el éxito en el campo debido a AlexNet en la competencia ImageNet 2012 (Krizhevsky et al., 2012) [\[22\]](#).
- Arquitecturas Region-based CNN (R-CNN, Fast R-CNN, Faster R-CNN): Desarrolladas por Girshick et al. (2014, 2015) y Ren et al. (2015), lo que permiten estas es que ambas combinan la propuesta de regiones con clasificación mediante el uso de CNN [\[23\]](#).
- Single Shot Detectors (SSD): Propuestos por Liu et al. (2016), estos son detectores los cuales permiten la predicción directa de las cajas delimitadoras y las clases en una sola pasada de la red [\[24\]](#).
- You Only Look Once (YOLO): Introducido por Redmon et al. (2016) en sus inicios no fue perfecto, ni aun lo es, pero ha ido perfeccionándose en versiones posteriores, YOLO tiene como objetivo la detección de objetos y la identificación de los mismos, logrando alta velocidad de inferencia en las pruebas y usos que se ha empleado [\[25\]](#).

En esta etapa con estos métodos basados en aprendizaje profundo no es novedoso mencionar que estos han superado significativamente a los enfoques anteriores en precisión, robustez y otros aspectos en general, los que lo ha llevado al punto de convertirse en el estándar actual para tareas de reconocimiento de objetos en las imágenes y videos.

Aplicaciones al reconocimiento de productos:

Cuando nos referimos al reconocimiento de productos esto representa un caso especial, debido a que presenta desafíos un tanto peculiares como son:

- La cantidad amplia de categorías y subcategorías que pueden existir.
- La gran similitud que pueden existir entre productos.
- La gran variedad en el tamaño, empaqueta y presentación.
- La dificultad de visualización en estanterías, almacenes o depósitos.
- Las variables condiciones de luz en los entornos.

No obstante a los desafíos mencionados anteriormente, recientes estudios han demostrado la viabilidad de estas implementaciones de sistemas automatizados para permitir el reconocimiento de productos en entornos reales:

- Goldman et al. (2019) alcanzaron una precisión del 94.7% en la identificación de productos en estanterías de supermercados con el uso de la arquitectura conocida como Faster R-CNN personalizada [\[26\]](#).
- Tonioni et al. (2020) lograron desarrollar una implementación capaz de permitir detectar como también contar los productos en tiempo real con una precisión del 92.3%, estos hicieron uso de una variante de YOLO de las cuales está optimizada para dispositivos móviles [\[27\]](#).
- Jain et al. (2022) hicieron la propuesta de un algoritmo de identificación automatizado con el uso de dos arquitecturas bastante conicidad hoy en dia como los son: InceptionV3 y MobileNet CNN para visión por computadora en refrigeradores inteligentes, demostrando la efectividad de estas técnicas en entornos controlados [\[28\]](#).

En el contexto de centros de acopios en particular, donde se conoce que los recursos computacionales son limitados, las arquitecturas como MobileNet, EfficientNet o ciertas versiones de YOLO de las optimizadas podrían representar opciones prometedoras, ya que equilibran lo que es la precisión y eficiencia misma debido a que son ligeros y eficaz.

1.1.3. Aprendizaje Profundo y Detección de Objetos

La inteligencia artificial junto con el aprendizaje profundo ha revolucionado el campo en el tema de la visión por computadora, debido a que proporcionan herramientas bastante poderosas con el objetivo de detectar y clasificar los objetos de forma automática que se encuentran en imágenes o videos.

Fundamentos de las Redes Neuronales Convolucionales (CNN):

Las CNN conforman lo que es la arquitectura fundamental para lidiar con el procesamiento de las imágenes en el aprendizaje profundo. Anteriormente se ha mencionado en dónde está basado su diseño que es el funcionamiento del córtex visual de los mamíferos, esto presenta varias características distintivas las cuales son:

1. **Capas convolucionales:** Estas se encargan de aplicar los filtros (kernels) a la imagen de entrada con el objetivo de detectar cuales son esas características locales como bordes, textura o formas. Cada uno de los filtros se desliza (convolución) encima de la imagen de este modo logrando generar mapas de características.
2. **Invariancia espacial:** Las CNN tienen la capacidad de identificar objetos independientemente de la posición en la imagen, todo esto es permitido gracias a la característica de compartición de pesos en las capas convolucionales.
3. **Jerarquía de abstracción:** En las capas existe una jerarquía que seguir, la primera capaz son las que se encargan de detectar las características básicas que componen una imagen como los bordes, esquinas, etc. Por otro lado, las capas más profundas son las que permiten capturar los detalles de alto nivel como formas, objetos completos.
4. **Pooling:** Existen técnicas como lo son el max-pooling o average-pooling las cuales brindan la capacidad de reducir la dimensionalidad espacial, permitiendo brindar una

robustez ante pequeñas transformaciones y así logrando reducir el costo computacional.

Arquitecturas para detección de objetos:

En el contexto del proyecto en cuestión Smart Stock Analyzer, es evidente que la arquitecturas que permitan la detección de objetos son relevantes, ya que no solo brindan la capacidad de identificar los productos en una imagen, sino que también localizan espacialmente y contarlos. Entre las principales arquitecturas incluyen:

1. Arquitecturas de dos etapas:

- **R-CNN (Regions with CNN features):** Propuesta por Girshick et al. (2014), está lo que permite es la combinación de las propuestas de regiones con CNN para permitir lo que es la clasificación. Es precisa en los aspectos que trata, pero también es computacionalmente costosa [\[23\]](#).
- **Fast R-CNN:** Las Fast R-CNN tienen la capacidad de lograr una mejora significativa en tema de eficiencia, ya que permite procesar la imagen completa con una CNN, para luego extraer aspectos y características para cada región propuesta.
- **Faster R-CNN:** Esta permite integrar una Red de Propuesta de Regiones (RPN) donde proporciona la habilidad de compartir capas convolucionales con la red de detección, de este modo logrando una aumentación significativa en el tema de la velocidad.
- **Mask R-CNN:** Extiende Faster R-CNN con el objetivo de permitir la segmentación de instancias, agregando una rama la cual se utiliza en predecir máscaras de objetos en paralelo con la detección de cajas.

2. Arquitecturas de una etapa:

- **YOLO (You Only Look Once):** Permite lidiar los aspectos de detección como un problema de regresión, de este modo lo que hace es que divide la imagen en diferentes celdas y de este modo prediciendo directamente cajas delimitadoras y probabilidades de clase. En cuestiones de rapidez y velocidad es significativamente más óptima que las arquitecturas de dos etapas, aunque en un principio menos precisa.
- **YOLOv3-v8:** Estas son extrapolaciones YOLO, pero mejoradas con características que las diferencian como predicciones a múltiples escalas y backbones más potentes, lo que brinda un mejor equilibrio entre la relación de velocidad y precisión.
- **SSD (Single Shot MultiBox Detector):** Hace uso de múltiples capas de características a diferentes escalas para de esta forma permitir detectar objetos de diversos tamaños, brindando un rendimiento eficiente en tiempo real.
- **RetinaNet:** Incluye una función de desviación de objetivo para tratar el desbalance entre ejemplos sencillos y complejos durante el entrenamiento.

3. Arquitecturas ligeras para dispositivos móviles:

- **MobileNet:** Específicamente creada para uso en dispositivos móviles, emplea convoluciones separables en profundidad para disminuir la complejidad informática.
- **EfficientDet:** Eficientemente incrementa tanto la resolución como la profundidad y anchura de la red, consiguiendo un rendimiento óptimo con recursos escasos.
- **YOLOv5-v8 (versiones "nano" y "small"):** Variaciones optimizadas para aparatos con limitaciones en los recursos computacionales.
- **SSD-Lite:** Versión más ligera del detector SSD, diseñada para móviles.

1.1.4. Implementación práctica y consideraciones:

Para el proyecto Smart Stock Analyzer, la aplicación de modelos de identificación de objetos requiere tener en cuenta diversos elementos clave:

1. Entrenamiento de modelos:

- **Conjuntos de datos:** Es fundamental elaborar un conjunto de datos que represente de manera representativa los productos de República Dominicana. Iniciativas como Open Food Facts ofrecen fundamentos que pueden ajustarse al entorno local.
- **Transfer learning:** Iniciar con modelos pre-entrenados en grandes conjuntos de datos (como COCO o ImageNet) y mejorarlos para productos concretos incrementa notablemente el rendimiento cuando se cuenta con datos escasos.
- **Aumento de datos:** Métodos como rotaciones, cambios de escala, cambios de brillo o contraste incrementan de manera efectiva el tamaño del conjunto de entrenamiento.
-

2. Inferencia eficiente:

- **Cuantización de modelos:** Disminuye la exactitud de los pesos de 32 bits a 8 bits o menos, reduciendo así el tamaño del modelo y acelerando la inferencia con la mínima pérdida de exactitud.
- **Poda de redes:** Elimina las conexiones neuronales redundantes o de menor relevancia, generando modelos más simplificados.
- **Optimización para hardware específico:** Implementaciones como TFLite (TensorFlow Lite) o ONNX Runtime facilitan optimizaciones particulares para diversos dispositivos móviles.

3. Evaluación de rendimiento:

- **Precisión media (mAP):** Métrica estándar que determina tanto la ubicación como la correcta categorización.
- **Tiempo de inferencia:** Es fundamental para las aplicaciones en tiempo real en dispositivos móviles.
- **Consumo de memoria:** Es crucial teniendo en cuenta las restricciones de los dispositivos móviles convencionales.

De acuerdo con un estudio de Ultralytics, YOLOv8 ha sido empleado para automatizar la administración de inventarios en supermercados, identificando y listando productos en estanterías. Esta aplicación facilita la identificación inmediata de productos que requieren reemplazo, economizando tiempo y disminuyendo gastos de trabajo, lo que indica su factibilidad para aplicaciones como Smart Stock Analyzer. [\[29\]](#).

1.1.4. Aplicaciones Móviles para Gestión de Inventarios

Las aplicaciones móviles han revolucionado de manera significativa la manera en que se llevan a cabo varias funciones corporativas, incluyendo la administración de inventarios. Principalmente, su popularidad se atribuye a su accesibilidad, portabilidad y el aumento de la capacidad computacional de los dispositivos móviles contemporáneos.

Evolución de las aplicaciones móviles para gestión de inventarios:

La evolución de las aplicaciones para la administración de inventarios en móviles ha ocurrido a la par del progreso tecnológico de los dispositivos y las redes:

1. **Primera generación (2000s):** Aplicaciones simples con características limitadas, especialmente para el escaneo de códigos de barras y el registro manual de entradas/salidas. Dependen de una sincronización continua con los sistemas centrales. (Laudon & Laudon, 2018) [\[30\]](#).
2. **Segunda generación (2010-2015):** Incluye herramientas de procesamiento en tiempo real, interfaces más fáciles de entender y características como la captura de imágenes

para la documentación. La mejora en la conectividad facilita una sincronización más eficiente con las bases de datos centrales.

3. **Tercera generación (2015-presente):** Incorporan tecnologías de vanguardia como la realidad aumentada, la identificación de imágenes, el procesamiento en la nube y la inteligencia artificial. Brindan análisis predictivo, funcionamiento fuera de internet con sincronización posterior, e integración con otros sistemas corporativos.

Arquitecturas y tecnologías para desarrollo móvil:

Para la creación de una aplicación como Smart Stock Analyzer, diversas arquitecturas y marcos de trabajo proporcionan beneficios particulares:

1. **Aplicaciones nativas:**
 - Específicamente creadas para una plataforma (iOS o Android)
 - Maximización del rendimiento y acceso total a las capacidades del dispositivo
 - Una experiencia de usuario excepcional.
 - Costo de desarrollo más elevado para cubrir diversas plataformas
2. **Aplicaciones híbridas:**
 - Fusionan tecnologías web (HTML5, CSS, JavaScript) con envoltorios autóctonos.
 - Desarrollo más veloz y asequible para diversas plataformas
 - Implementaciones como Ionic, Cordova o Capacitor.
 - Un desempeño un poco inferior a las aplicaciones nativas.
3. **Frameworks multiplataforma:**
 - **Flutter:** Google ha desarrollado este, emplea el lenguaje Dart y compila código nativo.
 - **Native React:** Utilizando JavaScript/React, crea interfaces locales.
 - **XAMARIN:** Utiliza C# y .NET para desarrollo en múltiples plataformas.
4. **Arquitecturas de aplicación:**
 - **MVC (Modelo-Vista-Controlador):** Diferencia datos, interfaz y lógica empresarial.

- **MVVM (Modelo-Vista-VistaModelo):** Mejora MVC con una vinculación de datos más eficiente
- **Clean Architecture:** Enfatiza la separación de responsabilidades y la independencia de frameworks

Para Smart Stock Analyzer, el uso de Flutter como marco de desarrollo brinda beneficios considerables:

- Performance similar al nativo, esencial para el procesamiento de imágenes.
- Consistente experiencia de usuario en Android (predominante en República Dominicana)
- Habilidad para compilar para diversas plataformas utilizando un único código base.
- Integración sólida con las APIs de cámara y el procesamiento visual
- Comunidad dinámica y múltiples bibliotecas a disposición.

Integración de visión por computadora en aplicaciones móviles:

La integración de habilidades de visión computacional en aplicaciones móviles plantea retos particulares que han sido enfrentados a través de diversas tácticas:

1. Procesamiento local vs. en la nube:

- **Enfoque local:** El procesamiento se lleva a cabo en su totalidad en el dispositivo, proporcionando autonomía de conexión pero restringida por la capacidad del hardware.
- **Enfoque basado en la nube:** Las imágenes son transmitidas a servidores para su procesamiento, posibilitando la creación de modelos más sofisticados pero necesitando conexión.
- **Enfoque híbrido:** Fusiona el procesamiento local para labores simples con el procesamiento en la nube para estudios más avanzados cuando existe conectividad.

2. Frameworks para visión por computadora móvil:

- **TensorFlow Lite:** La versión mejorada de TensorFlow para dispositivos móviles facilita la ejecución eficiente de modelos de aprendizaje profundo en el dispositivo.
- **ML Kit:** SDK de Google que facilita la incorporación de habilidades de ML en aplicaciones para móviles, incluyendo el reconocimiento de texto, la identificación de objetos y la categorización de imágenes.
- **CoreML:** Framework de Apple para incorporar modelos de aprendizaje automático en aplicaciones iOS.
- **PyTorch Mobile:** Implementación mejorada de PyTorch para inferencia en móviles.

3. Optimización de rendimiento:

- Utilización de modelos cuantificados (8-bit o incluso 4-bit) para disminuir las necesidades de memoria y procesamiento
- Procedimientos de aceleración hardware (GPU, NPU, DSP) mediante APIs como NNAPI (Android Neural Networks API)
- El procesamiento incremental o por lotes permite gestionar varias imágenes sin saturar el móvil.

Investigaciones actuales evidencian la factibilidad de sistemas de identificación visual en dispositivos móviles con recursos escasos. Por ejemplo, Howard et al. (2019) [\[31\]](#) evidenciaron que MobileNetV3, creado específicamente para equipos móviles, tiene la capacidad de alcanzar una precisión competitiva con modelos de mayor tamaño, manteniendo tiempos de inferencia prácticos en smartphones de gama media.

Casos de éxito en aplicaciones de inventario basadas en visión:

Varias recientes implementaciones evidencian la factibilidad de incorporar visión computacional en aplicaciones de administración de inventario:

1. **Trax Retail:** Emplea reconocimiento de imágenes para auditar estanterías de supermercados, detectando ausencias y problemas de presentación con exactitud que supera el 95% en circunstancias habituales de tienda [\[32\]](#).
2. **Shelfie Robot:** Fusiona dispositivos móviles con robots autónomos para escanear tiendas en su totalidad, empleando algoritmos de identificación de objetos para identificar y contar productos [\[33\]](#).
3. **Count-IT:** Aplicación que facilita a comercios pequeños la realización de inventarios a través de imágenes de estanterías, consiguiendo disminuir el tiempo de inventario en más del 80% en comparación con técnicas manuales [\[34\]](#).
4. **ShelfWatch:** Sistema que utiliza visión computacional para supervisar los inventarios en establecimientos de conveniencia, con la habilidad de reconocer más de 10,000 SKUs distintos con una precisión que supera el 92% [\[35\]](#).

Estos ejemplos evidencian que, con las tecnologías actuales, se puede crear una solución como Smart Stock Analyzer ajustada a las demandas particulares de los centros de acopios dominicanos, utilizando la facilidad de acceso a los dispositivos móviles y la potencia del aprendizaje profundo.

1.1.5. Procesamiento en la Nube vs. Edge Computing

En el desarrollo de soluciones informáticas fundamentadas en visión computacional para situaciones con recursos limitados, como los centros de acopios en República Dominicana, la selección del lugar para poner en práctica los algoritmos de procesamiento es un factor esencial que influye directamente en la accesibilidad y eficacia de la solución. Esta opción implica examinar los beneficios y desventajas de dos paradigmas esenciales: el procesamiento en la nube y el edge computing (procesamiento en el borde).

Procesamiento en la nube:

El procesamiento en la nube implica la transferencia de datos (en esta situación, imágenes) a servidores a distancia, donde se llevan a cabo los algoritmos de análisis y reconocimiento visual. Este método tiene varias particularidades significativas:

1. Ventajas:

- **Potencia de cómputo:** El acceso a recursos informáticos considerablemente más amplios que los existentes en dispositivos móviles, posibilitando el uso de modelos más sofisticados y exactos. (Varghese & Buyya, 2018) [\[36\]](#).
- **Escalabilidad:** Habilidad para gestionar cargas de trabajo fluctuantes sin alterar la infraestructura del cliente.
- **Continua actualización:** Las optimizaciones centrales de los algoritmos y modelos pueden realizarse sin necesidad de actualizaciones en los dispositivos de los usuarios.
- **Incorporación facilitada:** Incremento en la facilidad para conectar el sistema con otras plataformas o servicios corporativos.

2. Desventajas:

- **Dependencia de conectividad:** Necesita una conexión a internet para su funcionamiento, lo que puede resultar complicado en zonas con conectividad restringida o esporádica.

- **Latencia:** La duración requerida para enviar información al servidor y obtener respuestas puede influir en la experiencia del usuario en aplicaciones interactivas.
- **Costos recurrentes:** Los servicios en la nube generalmente conllevan gastos de suscripción constantes, lo que puede resultar complicado para entidades con presupuestos restringidos.
- **Privacidad y seguridad:** Impartir imágenes a servidores externos puede generar inquietudes respecto a la privacidad de la información.

Edge Computing (Procesamiento en el borde):

El edge computing traslada el procesamiento al "borde" de la red, es decir, a los equipos que recolectan los datos, reduciendo así la necesidad de interactuar con servidores remotos. En el contexto de Smart Stock Analyzer, esto conllevaría la aplicación directa de los algoritmos de identificación en los dispositivos móviles.

1. Ventajas:

- **Funcionamiento offline:** Habilidad para funcionar sin requerir una conexión constante a internet, esencial en zonas con escasez de conectividad.
- **Menor latencia:** Respuesta más ágil al suprimir el tiempo requerido para la transmisión de información.
- **Privacidad mejorada:** Los datos delicados se mantienen en el aparato del usuario, minimizando los peligros de privacidad.
- **Costos predecibles:** No es necesario hacer pagos constantes por los servicios en la nube.

2. Desventajas:

- **Limitaciones de recursos:** Los dispositivos móviles poseen capacidades de computación limitadas en comparación con los servidores en la nube, lo que podría restringir la complejidad de los modelos que se pueden utilizar.

- **Variabilidad de hardware:** El desempeño puede fluctuar considerablemente entre distintos dispositivos, dificultando así el desarrollo.
- **Complejidad de actualización:** La implementación de optimizaciones demanda la actualización de la aplicación en cada dispositivo.
- **Consumo de batería:** La intensificación del procesamiento puede influir en la duración de la batería del aparato.

Soluciones híbridas:

Para proyectos como Smart Stock Analyzer, un método híbrido que fusiona las ventajas de ambos paradigmas puede resultar ideal:

1. **Enfoque principal en edge computing:** Implementar modelos optimizados y leves directamente en dispositivos móviles para funciones elementales como la identificación y recuento de productos habituales, posibilitando el funcionamiento incluso sin conexión.
2. **Potenciación mediante procesamiento en la nube:**
 - Emplear servicios de nube para actividades más complejas cuando existe conectividad disponible
 - Registrar y añadir información cuando se conecta el dispositivo
 - Ofrecer análisis sofisticados que demandan mayor potencia informática

Investigaciones actuales, como la realizada por Shi et al. (2016) [\[37\]](#), evidencian que los sistemas de reconocimiento visual híbridos (edge-cloud) pueden disminuir el uso de datos hasta un 80% y optimizar los tiempos de respuesta en más del 60%, en contraposición a los métodos basados exclusivamente en la nube, sin poner en riesgo la exactitud. Esto indica que un modelo híbrido podría ser óptimo para centros de acopios en contextos con conectividad fluctuante, como los de República Dominicana, donde son esenciales la eficiencia en ancho de banda y la baja latencia.

1.2. Definición de Términos y Glosario

Centro de acopio: Establecimiento logístico diseñado para la acogida, categorización, almacenaje y reparto de mercancías, usualmente con propósitos humanitarios o de atención a emergencias.

Algoritmo: Conjunto de operaciones organizadas y limitadas que facilitan la identificación de la solución a un problema. En el campo de la computación, se refiere a la serie de comandos que una computadora realiza para llevar a cabo una tarea determinada.

API (Application Programming Interface): Conjunto de normas y procedimientos empleados para la creación e integración de software de aplicaciones, facilitando la comunicación entre distintos elementos del software.

Base de datos: Organización estructurada para la recopilación, almacenaje y recuperación de información. Dentro del marco del proyecto, guarda datos acerca de inventarios, productos y tendencias de consumo.

CNN (Convolutional Neural Network): Tipo de red neuronal artificial creada específicamente para manejar datos de estructura cuadrática, como imágenes, a través de capas de convolución que identifican patrones espaciales.

Cuantización: Método para disminuir la exactitud de los números en un modelo de aprendizaje profundo, reduciendo su volumen y optimizando la rapidez de inferencia con una pérdida mínima de exactitud.

Django: Framework de alto nivel de desarrollo web redactado en Python que promueve el desarrollo acelerado y un diseño ordenado y pragmático. Empleado en el desarrollo de backend del sistema..

Edge Computing: Paradigma de procesamiento que sitúa las capacidades de computación próximas a la fuente de los datos (en este escenario, en los dispositivos móviles), disminuyendo la latencia y la necesidad de conectividad.

Flutter: Framework de desarrollo para aplicaciones móviles multiplataforma, que emplea el lenguaje de programación Dart y facilita la creación de interfaces nativas para Android e iOS, creado por Google.

Inferencia: Procedimiento de emplear un modelo capacitado para realizar proyecciones acerca de nuevos datos. Dentro del marco del proyecto, hace referencia al estudio de imágenes para reconocer y narrar productos.

Inventario: Información registrada de los productos y stocks de un centro de acopio a una fecha específica.

IoT (Internet of Things): Red de objetos físicos ("cosas") que incluyen sensores, programas informáticos y otras tecnologías con el objetivo de vincularse e intercambiar información con otros aparatos y sistemas a través de internet.

Machine Learning (Aprendizaje Automático): Campo de la inteligencia artificial que emplea algoritmos y modelos estadísticos para optimizar el desempeño de los sistemas informáticos en una tarea determinada mediante la experiencia, sin necesidad de ser programados de manera explícita.

MobileNet: Familia de estructuras de redes neuronales convolucionales optimizadas para usos móviles y embebidos, que proporcionan un balance adecuado entre exactitud y eficacia computacional.

Modelo: Representación simplificada matemática de un sistema o proceso auténtico. En el aprendizaje automático, es el producto del entrenamiento con datos que permite realizar proyecciones (predicciones) o tomar resoluciones.

ONNX (Open Neural Network Exchange): Modelo de aprendizaje profundo abierto que facilita la interoperabilidad entre distintos marcos y herramientas.

PostgreSQL: Sistema de administración de bases de datos relacionales orientado a objetos, de código abierto y libre, reconocido por su solidez y adherencia a normas.

Procesamiento de imágenes: Conjunto de métodos para manejar y examinar imágenes en formato digital, que incluyen mejoras, transformaciones y obtención de datos.

Producto no perecedero: Artículo que posee una durabilidad extendida y no necesita condiciones particulares de almacenaje a corto plazo, como alimentos enlatados, agua en botellas o productos secos.

REST API: Modelo de arquitectura de software para sistemas distribuidos, en particular servicios web, que se fundamenta en el protocolo HTTP y facilita la interacción entre sistemas de computación.

TensorFlow: Google ha desarrollado una biblioteca de software libre para aprendizaje automático, que se utiliza extensamente para la creación y entrenamiento de modelos de redes neuronales.

TensorFlow Lite: La versión ligera de TensorFlow, creada para móviles y embebidos, facilita la ejecución de modelos de aprendizaje automático con recursos restringidos.

Transfer Learning: Técnica de aprendizaje automático en la que un modelo ya entrenado para una tarea se reutiliza como base para un modelo en otra tarea vinculada, disminuyendo así el tiempo de entrenamiento y los datos requeridos.

Visión por computadora: Sector de la inteligencia artificial que capacita a las computadoras para interpretar y entender el universo visual, facilitándoles la identificación y categorización de objetos en imágenes o vídeos.

YOLO (You Only Look Once): Conjunto de algoritmos de identificación de objetos en tiempo real que emplean una sola red neuronal en la imagen completa, segmentando la misma en áreas y prediciendo cajas de delimitación y probabilidades para cada zona.

Almacenamiento en la nube: Servicio que facilita el almacenamiento, acceso y administración de datos mediante internet en vez de en el disco duro local de un aparato.

Framework: Ambiente de software que ofrece estructura y características fundamentales para simplificar el desarrollo de aplicaciones.

OAuth 2.0: Protocolo de autorización estándar que habilita a aplicaciones de terceros para tener acceso restringido a un servicio HTTP, ya sea en representación del dueño del recurso a

través de la coordinación de una interacción de aprobación entre el dueño del recurso y el servicio HTTP, o permitiendo a la aplicación de terceros tener acceso en su propio nombre.

Capítulo II - Solución Propuesta

2.1. Definición del Proyecto


2.1.1. Definición

El proyecto consiste en la elaboración de un sistema que sirva como solución al problema planteado anteriormente en los centros de acopio. Esta solución será capaz de capturar imágenes de conjuntos de productos no perecederos, identificarlos y clasificarlos mediante reconocimiento visual. A partir de esta información, el sistema generará un inventario inicial detallado. Posteriormente, mediante la captura periódica de nuevas imágenes, realizará un análisis comparativo entre el estado actual del inventario y el registro inicial establecido. Como resultado, proporcionará informes precisos que indicarán qué productos deben reponerse para mantener los niveles deseados de existencias.

Asimismo, el sistema permitirá a los usuarios consultar el inventario actualizado mediante categorías específicas, lo que facilitará el acceso inmediato a productos prioritarios durante situaciones de emergencia.

Adicionalmente, la plataforma incorporará funcionalidades avanzadas para la generación de reportes analíticos basados en diversas métricas relevantes, incluyendo:

- Consumo de productos por categoría individual o múltiple en períodos semanales.
- Análisis del uso de productos por categoría individual o múltiple en períodos mensuales.



Diseño general del sistema

2.1.2. Componentes

El sistema Smart Stock Analyzer se estructura en tres componentes principales interconectados que funcionan en armonía para ofrecer una solución completa de gestión de inventario para centros de acopio. A continuación, detallamos cada uno de estos componentes:

2.1.2.1. Modelo de visión computacional

El núcleo analítico del sistema se fundamenta en un modelo de visión computacional que utiliza técnicas avanzadas de aprendizaje profundo para identificar y clasificar productos no perecederos a través de imágenes. Este modelo implementa redes neuronales convolucionales basadas en la variante avanzada de YOLO, optimizada para detección de objetos.

El modelo ha sido diseñado con capacidad para identificar y clasificar siete categorías distintas de productos no perecederos: bebidas, lácteos, cereales, alimentos enlatados, galletas/crackers, pastas/fideos y condimentos. Cada una de estas categorías corresponde a

grupos de productos esenciales en los centros de acopio de la República Dominicana, facilitando así una gestión de inventario más granular y efectiva.

En cuanto a los parámetros de rendimiento, el sistema establece como objetivo alcanzar un umbral mínimo del 85% de precisión en la detección para cada categoría definida. Este alto nivel de fiabilidad es esencial para garantizar que los inventarios generados automáticamente reflejen con exactitud las existencias reales del centro de acopio, permitiendo así una toma de decisiones estratégica basada en datos precisos.

El modelo ha sido entrenado utilizando un conjunto de datos extenso y diverso, compuesto por más de 100,000 imágenes procedentes del repositorio Open Food Facts, complementado con fotografías tomadas en entornos reales de centros de acopio dominicanos. Esta combinación de fuentes de entrenamiento optimiza la capacidad del sistema para reconocer productos específicos del contexto local, mejorando significativamente la precisión operativa del sistema en el entorno de implementación previsto.

2.1.2.2. Backend en Django

El backend funciona como el cerebro organizativo del sistema, gestionando la comunicación entre la aplicación móvil y el modelo de visión computacional, además de administrar el almacenamiento y procesamiento de datos.

Este apartado sirve para implementar una API RESTful que facilita la comunicación eficiente entre el frontend y los servicios de procesamiento. Asimismo, protege el acceso a dicha comunicación mediante un sistema de autenticación basado en JWT. Esta implementación de seguridad protege la integridad y confidencialidad de los datos sensibles de los centros de acopio. Previene accesos no autorizados a información crítica como inventarios, patrones de consumo y datos de usuarios, mitigando potenciales vulnerabilidades ante intentos de apropiación indebida de información o manipulación del sistema.

Este componente del sistema es desplegado en conjunto con una capa de persistencia de datos PostgreSQL. Esta se utiliza para el almacenamiento de la estructura que datos con una estructura relacional que comprende todas nuestras entidades que requieren de persistencia. Además, los datos están distribuidos de tal manera que la información se encuentra organizada por cada centro de acopio.

El motor PostgreSQL versión 16 se despliega como un servicio containerizado mediante Docker, lo que facilita su gestión, respaldo y escalabilidad. Esta configuración proporciona aislamiento y portabilidad, permitiendo una administración consistente en diversos entornos de implementación.

El sistema incorpora una arquitectura de procesamiento asíncrono diseñada específicamente para gestionar múltiples solicitudes de análisis de imágenes de manera simultánea. Esta capacidad constituye un elemento crítico de la infraestructura, considerando que los centros de acopio pueden requerir la digitalización de grandes volúmenes de productos en períodos concentrados, especialmente durante inventarios iniciales o actualizaciones masivas.

2.1.2.3. Aplicación móvil en Flutter

La interfaz de usuario principal desarrollada en Flutter proporciona una experiencia intuitiva y accesible para los operadores de los centros de acopio, permitiéndoles interactuar con todas las funcionalidades del sistema desde distintos dispositivos móviles gracias a sus capacidades multiplataforma.

La interfaz tiene un diseño centrado en el usuario con validación de campos en tiempo real, estados de carga claramente indicados y retroalimentación visual inmediata. Asimismo, implementa una funcionalidad de captura y selección de imágenes que resulta entendible para el usuario promedio.

En este sistema el usuario puede ver una presentación clara de los resultados de los análisis de imágenes y visualizar información detallada sobre los productos detectados. Como funcionalidad adicional, se puede consultar y administrar el inventario de un centro, permitiendo filtrar productos por categorías y generando alertas sobre niveles críticos.

2.1.3. Integración de Componentes

Estos tres componentes funcionan de manera sincronizada siguiendo un flujo de trabajo definido:

1. El usuario captura una imagen a través de la aplicación móvil, que se envía al backend.

2. El backend procesa la imagen utilizando el modelo de visión computacional para identificar y clasificar los productos.
3. Los resultados del análisis se almacenan en la base de datos y se devuelven a la aplicación móvil.
4. La aplicación presenta los resultados al usuario de manera clara y accesible.
5. El sistema compara los resultados con el inventario base para generar alertas y recomendaciones de reposición.

Esta arquitectura modular permite que cada componente se desarrolle y optimice de manera independiente, manteniendo la cohesión del sistema en su conjunto. Además, facilita la escalabilidad futura, permitiendo expandir funcionalidades específicas sin necesidad de rediseñar todo el sistema.

El sistema Smart Stock Analyzer representa así una solución completa y sofisticada para la gestión automatizada de inventarios en centros de acopio, combinando tecnologías avanzadas de inteligencia artificial con una interfaz accesible y una infraestructura robusta.

2.2. Productos del Proyecto

2.2.1. Delimitación del alcance

El proyecto Smart Stock Analyzer está diseñado específicamente para abordar la problemática de gestión de inventarios en centros de acopio de la República Dominicana. Su alcance se define con precisión para garantizar la entrega de una solución viable y efectiva dentro de los parámetros de tiempo y recursos disponibles.

Lo que el proyecto incluye:

1. **Aplicación móvil para gestión de inventario:** Una aplicación desarrollada en Flutter que proporciona una interfaz intuitiva para usuarios con diversos niveles de conocimiento tecnológico. Esta aplicación permite capturar imágenes de productos almacenados, visualizar resultados de análisis, y gestionar información básica de inventario.
2. **Sistema de reconocimiento visual:** Un modelo de visión computacional basado en arquitectura YOLOv8x, específicamente entrenado para identificar y clasificar productos no perecederos en siete categorías definidas (bebidas, lácteos, cereales, enlatados, galletas/crackers, pastas/fideos y condimentos).
3. **Backend para procesamiento y gestión:** Una infraestructura de servidor desarrollada en Django que facilita la comunicación entre la aplicación móvil y el modelo de visión computacional, procesa las solicitudes de análisis, y gestiona el almacenamiento de datos e imágenes.
4. **Base de datos relacional:** Un sistema PostgreSQL que almacena de manera estructurada toda la información relacionada con centros de acopio, usuarios, imágenes capturadas, y resultados de detección, siguiendo un esquema optimizado para consultas eficientes.
5. **Generación de inventario inicial automatizado:** Funcionalidad que permite crear un inventario base a partir de fotografías del área de almacenamiento, identificando y categorizando automáticamente los productos presentes.

6. **Actualización periódica de inventario:** Capacidad para comparar imágenes nuevas con el inventario base, generando reportes de productos consumidos y listas de reposición.
7. **Sistema de alertas de stock:** Mecanismo que notifica al usuario cuando los niveles de inventario de ciertos productos alcanzan umbrales críticos predefinidos.
8. **Análisis básico de datos de consumo:** Funcionalidad para generar estadísticas simples sobre patrones de consumo de productos, utilizando la información recopilada a través del tiempo.
9. **Soporte para múltiples centros de acopio:** Capacidad para gestionar varios centros de forma independiente, manteniendo la información separada y segura.
10. **Autenticación y autorización de usuarios:** Sistema de gestión de accesos basado en JWT que garantiza que solo personal autorizado pueda acceder a la información específica de su centro.
11. **Manual de usuario y documentación técnica:** Recursos informativos completos que facilitan la implementación, uso y mantenimiento del sistema.

Lo que el proyecto no incluye:

1. **Integración con sistemas externos:** El sistema no se integrará con plataformas ERP, sistemas contables, o aplicaciones de terceros existentes en los centros de acopio.
2. **Funcionalidades de comercio electrónico:** No se incluyen capacidades para la venta directa de productos, gestión de órdenes, o procesamiento de pagos.
3. **Reconocimiento de productos perecederos:** El modelo de visión computacional está optimizado exclusivamente para productos no perecederos, excluyendo alimentos frescos, refrigerados o congelados.
4. **Gestión de fechas de caducidad:** No se implementará seguimiento de fechas de vencimiento o sistemas de rotación de inventario basados en caducidad.

5. **Análisis predictivo avanzado:** No se incluyen algoritmos de predicción de demanda, optimización de inventario, o recomendaciones de compra basadas en inteligencia artificial.
6. **Gestión de proveedores o logística:** El sistema no administrará información de proveedores, procesos de compra, o logística de distribución.
7. **Versión web completa:** No se desarrollará una aplicación web complementaria, limitándose a una interfaz de administración básica para gestión del sistema.
8. **Operación completamente offline:** Aunque soporta conectividad intermitente, el sistema requiere conexión a internet para sus funcionalidades principales de análisis y sincronización.
9. **Gestión financiera o contable:** No se incluyen módulos para valoración de inventario, cálculo de costos, o generación de informes financieros.
10. **Integración con sistemas de código de barras o RFID:** El sistema se basa exclusivamente en reconocimiento visual, sin integración con tecnologías complementarias de identificación.
11. **Soporte para múltiples idiomas:** La interfaz estará disponible únicamente en español, adaptada al contexto dominicano.
12. **Asesoramiento nutricional personalizado:** No se incluyen funcionalidades para análisis nutricional o recomendaciones dietéticas basadas en los productos inventariados.
13. **Sistema de distribución o asignación:** No se desarrollarán módulos para la gestión de la distribución de productos a beneficiarios o la asignación de recursos en situaciones de emergencia.

2.2.2. Entregables

Pre-Proyecto (ISC) - A entregar el 2 de abril de 2025

El núcleo fundamental de la aplicación que constituye el entregable para la etapa de Pre-Proyecto comprende los siguientes componentes:

1. **Modelo de visión computacional funcional:** Un sistema de reconocimiento visual capaz de identificar y clasificar productos no perecederos en siete categorías con una precisión mínima del 60% para cada clase.
2. **Aplicación móvil con funcionalidades esenciales:** Una interfaz de usuario desarrollada en Flutter que permite:
 - Registro y autenticación de usuarios
 - Gestión de centros de acopio
 - Captura de imágenes mediante la cámara del dispositivo
 - Visualización de resultados de análisis
3. **Infraestructura backend desplegada:** Un sistema backend implementado en Django y alojado en la nube (DigitalOcean) que incluye:
 - API RESTful para comunicación con la aplicación móvil
 - Integración con el modelo de visión computacional
 - Base de datos PostgreSQL con esquema relacional implementado
 - Sistema de almacenamiento de imágenes
 - Autenticación basada en JWT

Proyecto Final (ISC) - Entregable Completo

El entregable final expandirá significativamente las capacidades del sistema inicial, incorporando:

1. **Modelo de visión computacional optimizado:** Mejora de la precisión hasta alcanzar un mínimo del 85% para cada categoría, mediante refinamiento del entrenamiento e incorporación de técnicas avanzadas de preprocesamiento de imágenes.
2. **Aplicación móvil con funcionalidades avanzadas:**
 - Generación de inventario base
 - Actualización periódica mediante comparación de imágenes
 - Sistema de alertas para niveles críticos de stock
 - Informes estadísticos de consumo y utilización
 - Interfaz mejorada con filtros de consulta por categorías
3. **Backend con capacidades ampliadas:**
 - Procesamiento asíncrono para múltiples solicitudes simultáneas
 - Algoritmos de comparación para detectar cambios en inventario
 - Sistema de notificaciones para alertas de stock
 - API expandida para soportar funcionalidades adicionales
 - Optimización para rendimiento con volúmenes elevados de datos
4. **Escenario para validación final:** El sistema será validado preferentemente en un centro de acopio real o, alternativamente, en un entorno simulado a gran escala con al menos 15-50 productos diversos. La validación comprenderá:
 - Pruebas extensivas de todas las funcionalidades implementadas
 - Evaluación de precisión y rendimiento bajo condiciones de uso intensivo
 - Verificación de la utilidad práctica del sistema para gestores de inventario

Este plan de entregables ha sido estructurado para garantizar que el desarrollo cumpla con los requisitos académicos de las etapas del proyecto, mientras se construye progresivamente una solución completa y funcional que responda a las necesidades reales de los centros de acopio en la República Dominicana.

2.2.3. Acuerdo con el Asesor

Tras reuniones de planificación y evaluación con el asesor, Máximo Emiliano Perez Medrano, se ha acordado que el núcleo de la aplicación para la etapa de Anteproyecto (ICC) consistirá en:

1. Modelo de visión computacional funcional capaz de identificar y clasificar productos no perecederos en las siete categorías definidas, con una precisión mínima del 60%.
2. Aplicación móvil con interfaz de usuario que permita capturar imágenes, enviarlas al servidor para procesamiento, y visualizar los resultados del análisis.
3. Backend en Django desplegado en la nube que integre el modelo de visión computacional y gestione la comunicación con la aplicación móvil.

2.3. Cronograma del Proyecto

El desarrollo del proyecto Smart Stock Analyzer se ha estructurado en dos fases principales: Pre-Proyecto (ISC) y Proyecto Final (ISC), cada una con actividades específicas, responsables asignados y plazos definidos para garantizar una implementación metódica y controlada de todos los componentes del sistema.

2.3.1. Cronograma de Pre-Proyecto (ISC)

2.3.1.1. Primer Entregable - Fecha estimada: 18 de febrero de 2025

Configuración del entorno de desarrollo (20 al 25 de enero de 2025)

Responsable: Randae García

Implementación del repositorio Git, configuración de ambientes de desarrollo y pruebas para garantizar un flujo de trabajo eficiente durante todo el proyecto.

Implementación básica de CI/CD (26 al 28 de enero de 2025)

Responsable: Starlin Frías

Configuración de pipeline básico para integración y despliegue continuo, facilitando la automatización de pruebas y despliegue.

Diseño de arquitectura inicial (22 al 25 de enero de 2025)

Responsable: Ambos

Definición de los componentes principales y las relaciones entre los diferentes sistemas que conformarán la solución integral.

Recopilación del dataset inicial (26 de enero al 1 de febrero de 2025)

Responsable: Starlin Frías

Selección y organización de imágenes para el entrenamiento inicial del modelo de visión computacional, estableciendo las categorías principales.

Desarrollo de la estructura básica de la aplicación móvil (28 de enero al 3 de febrero de 2025)

Responsable: Randae García

Configuración inicial de Flutter, implementación de la estructura de navegación y diseño básico de la interfaz de usuario.

Implementación del sistema de autenticación (4 al 9 de febrero de 2025)

Responsable: Ambos

Desarrollo del módulo de registro y login de usuarios, implementando JWT para la gestión segura de sesiones.

Entrenamiento inicial del modelo (1 al 18 de febrero de 2025)

Responsable: Randae García

Configuración e implementación del entrenamiento del modelo YOLO con el dataset inicial para establecer una línea base de precisión.

Implementación de detección básica (12 al 16 de febrero de 2025)

Responsable: Starlin Frías

Desarrollo del sistema de reconocimiento inicial, integrando el modelo entrenado con la capacidad de procesar imágenes y devolver categorías.

Pruebas y validación del entregable (17 al 18 de febrero de 2025)

Responsable: Ambos

Verificación funcional de todos los componentes desarrollados para garantizar su correcto funcionamiento antes de la entrega formal.

2.3.1.2. Segundo Entregable - Fecha estimada: 18 de marzo de 2025

Desarrollo de funcionalidad de captura de fotos (19 al 26 de febrero de 2025)

Responsable: Randae García

Implementación del módulo en la aplicación móvil que permite capturar imágenes directamente o seleccionadas de la galería del dispositivo.

Configuración de infraestructura cloud (19 al 23 de febrero de 2025)

Responsable: Starlin Frías

Provisión y configuración de servicios en DigitalOcean, incluyendo la implementación de Droplets para el backend y servicios complementarios.

Diseño e implementación del esquema de base de datos (24 de febrero al 2 de marzo de 2025)

Responsable: Starlin Frías

Desarrollo del modelo relacional en PostgreSQL, definiendo las entidades principales (usuarios, centros, imágenes, detecciones) y sus relaciones.

Expansión del dataset (24 de febrero al 5 de marzo de 2025)

Responsable: Starlin Frías

Incorporación de nuevas imágenes y mejora de la diversidad del conjunto de datos, incrementando la representatividad de todas las categorías de productos.

Refinamiento del etiquetado (6 al 11 de marzo de 2025)

Responsable: Starlin Frías

Revisión y mejora de las etiquetas en el dataset, optimizando la precisión de las clasificaciones y corrigiendo inconsistencias.

Desarrollo del sistema de almacenamiento de imágenes (3 al 10 de marzo de 2025)

Responsable: Starlin Frías

Implementación del componente para gestión y persistencia de imágenes en el backend, con organización por centro de acopio.

Ampliación de categorías de productos (12 al 16 de marzo de 2025)

Responsable: Starlin Frías

Expansión del modelo para soportar las siete categorías definitivas de productos no perecederos, adaptando el entrenamiento.

Pruebas y validación del entregable (17 al 18 de marzo de 2025)

Responsable: Ambos

Verificación funcional del sistema integrado, asegurando la correcta comunicación entre componentes y el cumplimiento de los objetivos establecidos.

2.3.1.3. Tercer Entregable - Fecha estimada: 8 de abril de 2025

Optimización del modelo (19 al 27 de marzo de 2025)

Responsable: Starlin Frías

Mejoras en la arquitectura del modelo para aumentar la precisión en todas las categorías, implementando técnicas avanzadas de entrenamiento.

Desarrollo del sistema de procesamiento de imágenes (19 al 26 de marzo de 2025)

Responsable: Ambos

Implementación del componente que gestiona el flujo completo de procesamiento desde la captura hasta la presentación de resultados.

Mejora de la API backend (27 de marzo al 2 de abril de 2025)

Responsable: Starlin Frías

Optimización de los endpoints de la API para soportar todas las operaciones requeridas, incluyendo la gestión asíncrona de solicitudes.

Validación cruzada del modelo (28 de marzo al 2 de abril de 2025)

Responsable: Randae García

Implementación de técnicas de validación cruzada para evaluar objetivamente el rendimiento del modelo en diferentes escenarios.

Integración completa del sistema (3 al 6 de abril de 2025)

Responsable: Ambos

Asegurar la correcta comunicación y funcionamiento entre todos los componentes desarrollados, desde la aplicación móvil hasta el backend y modelo.

2.3.2. Cronograma de Proyecto Final (ISC)

2.3.2.1. Cuarto Entregable - Fecha estimada: 31 de mayo de 2025

Optimización de precisión del modelo (9 al 22 de abril de 2025)

Responsable: Starlin Frías

Implementación de técnicas avanzadas para mejorar la precisión del modelo en todas las categorías, alcanzando el objetivo mínimo del 85%.

Optimización de velocidad de procesamiento (23 al 30 de abril de 2025)

Responsable: Starlin Frías

Mejoras en el pipeline de procesamiento para reducir los tiempos de respuesta, implementando técnicas de optimización y paralelización.

Desarrollo del sistema de validación avanzado (1 al 10 de mayo de 2025)

Responsable: Starlin Frías

Implementación de métricas y metodologías de evaluación para verificar objetivamente el rendimiento del modelo en distintos escenarios.

Desarrollo del sistema de generación de inventario base (9 al 22 de abril de 2025)

Responsable: Randae García

Implementación del componente que permite crear un inventario inicial automatizado a partir de imágenes del área de almacenamiento.

Desarrollo del sistema de comparación de inventarios (23 de abril al 15 de mayo de 2025)

Responsable: Randae García

Implementación del mecanismo que compara inventarios a lo largo del tiempo, identificando cambios y generando informes de consumo.

Pruebas en diversos escenarios (16 al 27 de mayo de 2025)

Responsable: Ambos

Validación del sistema en diferentes condiciones de iluminación, distribución de productos y volumen de inventario.

Validación final del entregable (28 al 31 de mayo de 2025)

Responsable: Ambos

Verificación funcional completa y preparación de la documentación correspondiente.

2.3.2.2. Quinto Entregable - Fecha estimada: 28 de junio de 2025

Implementación de dashboard con métricas básicas (1 al 12 de junio de 2025)

Responsable: Randae García

Desarrollo de interfaz para visualización de métricas clave como niveles de stock, consumo por categoría y precisión de detección.

Desarrollo del sistema de alertas (13 al 19 de junio de 2025)

Responsable: Randae García

Implementación del mecanismo que notifica al usuario cuando los niveles de inventario alcanzan umbrales críticos predefinidos.

Implementación de categorización y etiquetado automático (1 al 15 de junio de 2025)

Responsable: Starlin Frías

Desarrollo del componente que asigna automáticamente etiquetas y categorías a los productos detectados, facilitando su gestión.

Desarrollo del sistema de conteo manual (16 al 22 de junio de 2025)

Responsable: Randae García

Implementación de la funcionalidad que permite a los usuarios verificar y ajustar manualmente las cantidades detectadas si es necesario.

Integración y pruebas del sistema completo (23 al 26 de junio de 2025)

Responsable: Ambos

Verificación del funcionamiento integrado de todos los componentes desarrollados en esta etapa.

Documentación del entregable (27 al 28 de junio de 2025)

Responsable: Ambos

Preparación de la documentación técnica y demostración del sistema.

2.3.2.3. Sexto Entregable - Fecha estimada: 25 de julio de 2025

Implementación de generación automática de listas de reposición (29 de junio al 8 de julio de 2025)

Responsable: Starlin Frías

Desarrollo del sistema que genera automáticamente recomendaciones de productos a reponer basándose en los niveles de inventario y patrones de consumo.

Desarrollo de reportes personalizados (9 al 15 de julio de 2025)

Responsable: Starlin Frías

Implementación de un sistema flexible que permite a los usuarios generar informes adaptados a sus necesidades específicas.

Implementación de métricas avanzadas de inventario (29 de junio al 8 de julio de 2025)

Responsable: Randae García

Desarrollo de indicadores sofisticados que proporcionan insights sobre rotación de productos, frecuencia de consumo y eficiencia del inventario.

Preparación para despliegue en centro piloto (9 al 15 de julio de 2025)

Responsable: Ambos

Configuración final del sistema para su implementación en un entorno real o simulado que refleje las condiciones operativas de un centro de acopio.

Elaboración de documentación completa (16 al 20 de julio de 2025)

Responsable: Ambos

Desarrollo de manuales técnicos, guías de usuario y documentación de API para facilitar el uso y mantenimiento del sistema.

Pruebas finales de integración y validación (21 al 23 de julio de 2025)

Responsable: Ambos

Verificación exhaustiva del funcionamiento de todos los componentes bajo condiciones que simulan el uso real del sistema.

2.4. Plan de Administración de Riesgos

La implementación exitosa del proyecto Smart Stock Analyzer requiere un enfoque estructurado para la identificación, evaluación y gestión de los riesgos que podrían comprometer sus objetivos. Comprendemos que el desarrollo de una solución tecnológica innovadora como la nuestra conlleva incertidumbres inherentes que deben ser gestionadas proactivamente.

2.4.1. Enfoque metodológico para la evaluación de riesgos

Nuestro enfoque para la evaluación de riesgos sigue un proceso sistemático que garantiza la identificación temprana y la gestión eficaz de las amenazas potenciales al proyecto:

1. **Identificación de riesgos:** Mediante sesiones colaborativas de lluvia de ideas, análisis de documentación técnica y revisión de proyectos similares, hemos identificado los riesgos potenciales que podrían afectar nuestro proyecto.
2. **Análisis cualitativo:** Cada riesgo identificado ha sido evaluado según dos dimensiones principales:
 - **Probabilidad de ocurrencia:** Alta (>70%), Media (30-70%), o Baja (<30%)
 - **Impacto potencial:** Crítico (compromete los objetivos fundamentales), Moderado (afecta parcialmente los objetivos), o Bajo (impacto manejable)
3. **Priorización:** Basándonos en la combinación de probabilidad e impacto, hemos clasificado los riesgos en tres niveles de prioridad:
 - **Prioridad alta:** Requieren atención inmediata y planes de respuesta detallados
 - **Prioridad media:** Requieren monitoreo constante y planes de contingencia
 - **Prioridad baja:** Requieren seguimiento periódico
4. **Planificación de respuestas:** Para cada riesgo identificado, hemos desarrollado estrategias específicas de respuesta, asignando responsabilidades claras dentro del equipo de proyecto.

5. **Monitoreo y control:** Implementaremos un proceso continuo de seguimiento para detectar señales tempranas de materialización de riesgos y evaluar la efectividad de las medidas preventivas.

2.4.2. Matriz de Riesgos y Planes de Respuesta

2.4.2.1. Matriz de Riesgos

Riesgo	Probabilidad	Impacto	Responsable	Estrategia
R1: Precisión insuficiente del modelo	Media	Crítico	Ambos	Mitigar
R2: Limitaciones de infraestructura de procesamiento	Alta	Moderado	Starlin Frías	Mitigar
R3: Dificultades de integración entre componentes	Media	Moderado	Ambos	Evitar
R4: Rendimiento deficiente en dispositivos móviles	Baja	Moderado	Randae Garcia	Mitigar
R5: Indisponibilidad de centros de acopio para validación	Alta	Moderado	Ambos	Aceptar / Mitigar
R6: Cambios en requisitos o alcance	Media	Crítico	Randae Garcia	Evitar
R7: Fallos en la infraestructura cloud	Baja	Alto	Starlin Frías	Mitigar

2.4.2.2. Planes de Acción y Puntos de Activación

R1: Precisión insuficiente del modelo

Plan de Acción:

1. Ampliar y diversificar el dataset de entrenamiento
2. Experimentar con arquitecturas alternativas de redes neuronales
3. Implementar técnicas de data augmentation más avanzadas

Punto de Activación: Precisión por debajo del 60% en cualquier categoría durante la fase de validación

R2: Limitaciones de infraestructura de procesamiento

Plan de Acción:

1. Utilizar servicios en la nube para entrenamiento (Google Colab Pro)
2. Optimizar hiperparámetros para reducir requisitos de memoria
3. Implementar entrenamiento por lotes

Punto de Activación: Tiempos de entrenamiento superiores a 72 horas o errores de memoria

R3: Dificultades de integración entre componentes

Plan de Acción:

1. Desarrollar prototipos de integración temprana
2. Establecer APIs bien documentadas
3. Implementar pruebas automatizadas de integración

Punto de Activación: Fallos en la transmisión de datos o inconsistencias entre componentes

R4: Rendimiento deficiente en dispositivos móviles

Plan de Acción:

1. Optimizar el tamaño de las imágenes antes de la transmisión
2. Implementar técnicas de carga progresiva
3. Realizar pruebas en diversos dispositivos

Punto de Activación: Tiempos de respuesta superiores a 5 segundos o consumo de memoria >200MB

R5: Indisponibilidad de centros de acopio para validación**Plan de Acción:**

1. Desarrollar escenario alternativo controlado
2. Establecer contactos institucionales con anticipación
3. Flexibilizar los requisitos de validación

Punto de Activación: No confirmación de acceso a un centro real 4 semanas antes de la fecha de validación

R6: Cambios en requisitos o alcance**Plan de Acción:**

1. Documentar formalmente los requisitos acordados
2. Implementar metodología ágil con sprints cortos
3. Mantener comunicación constante con asesores

Punto de Activación: Solicitud de cambios que afecten más del 20% de las funcionalidades ya implementadas

R7: Fallos en la infraestructura cloud

Plan de Acción:

1. Implementar configuración de alta disponibilidad
2. Establecer procedimientos de backup automáticos
3. Documentar procesos de recuperación

Punto de Activación: Tiempo de inactividad superior a 4 horas

2.4.3. Estrategias Para el Manejo de Riesgos

Nuestro enfoque para la gestión de riesgos se basa en tres estrategias principales:

Evitar el Riesgo

Para riesgos de alto impacto y probabilidad significativa, implementaremos medidas preventivas que eliminen la posibilidad de ocurrencia:

- Estableceremos requisitos formales documentados al inicio del proyecto para evitar cambios significativos de alcance.
- Desarrollaremos prototipos de integración temprana para identificar y resolver problemas de comunicación entre componentes antes de que escalen.
- Implementaremos prácticas de desarrollo seguro y auditorías periódicas para prevenir vulnerabilidades de seguridad.

Mitigar el Riesgo

Para riesgos que no pueden evitarse completamente, adoptaremos estrategias para reducir su probabilidad o impacto:

- Ampliaremos continuamente nuestro dataset de entrenamiento y exploraremos técnicas avanzadas de preprocesamiento para mejorar la precisión del modelo.
- Utilizaremos servicios cloud escalables para superar limitaciones de recursos computacionales.

- Desarrollaremos escenarios alternativos de validación para mitigar la posible indisponibilidad de centros de acopio reales.
- Realizaremos pruebas de rendimiento en diversos dispositivos para optimizar la experiencia móvil.

Aceptar el Riesgo

Para riesgos de bajo impacto o baja probabilidad donde las medidas preventivas resultan excesivamente costosas:

- Aceptaremos limitaciones menores en funcionalidades no críticas si su implementación completa compromete los plazos del proyecto.
- Estableceremos márgenes de tiempo en la planificación para absorber retrasos menores.
- Prepararemos escenarios alternativos de demostración en caso de que no sea posible acceder a un centro de acopio real.

Monitoreo y Puntos de Activación

Hemos definido indicadores específicos y umbrales cuantitativos como puntos de activación para cada plan de respuesta. Estos indicadores serán monitoreados regularmente en reuniones semanales de seguimiento donde:

1. Se evaluará el estado actual de cada riesgo identificado.
2. Se verificará si algún punto de activación ha sido alcanzado.
3. Se implementarán los planes de respuesta correspondientes cuando sea necesario.
4. Se identificarán nuevos riesgos emergentes no considerados previamente.

Este enfoque estructurado para la gestión de riesgos nos permitirá mantener el proyecto en curso hacia sus objetivos, adaptándonos proactivamente a los desafíos que puedan surgir durante su desarrollo e implementación.

2.5. Presupuesto

Descripción	Propósito	Costo \$DOP	Costo \$USD
Unidades en Google Collab	Entrenamiento del modelo en la nube	1240	20\$
Droplet en Digital Ocean	Despliegue de backend y modelo	Por uso	Por uso
DNS en name.com	Asociar dirección IP de droplet	1,265	20\$
2 PCs personales	Desarrollo de los sistemas	80,000	1,265\$
2 Dispositivos móviles	Implementar la aplicación móvil en el ecosistema objetivo	60,000	947\$

Tabla de Presupuesto del proyecto

Desglose

- Unidades en Google Collab: Necesarias para el entrenamiento eficiente e ininterrumpido de nuestro modelo en un ambiente en la nube.
- Droplet en Digital Ocean: Utilizada para desplegar nuestra aplicación backend y modelo de IA en un ambiente en la nube. Funciona para permitir una conexión global con cualquier instancia de la aplicación móvil.
- DNS en name.com: Sirve para asociar la dirección IP de nuestro droplet en Digital Ocean a una nombre entendible.
- 2 PCs personales: PCs personales pertenecientes a cada uno de los integrantes previamente al comienzo del proyecto. Son utilizadas para el diseño, implementación e integración del sistema planteado en su totalidad.
- 2 Dispositivos móviles: Utilizados para hacer pruebas de la aplicación móvil y presentar resultados.

2.6. Definición de la demostración

2.6.1. Lugar

La demostración de nuestro proyecto tendrá lugar en un centro de acopio. Este lugar y el proceso de pruebas irán de acorde a los problemas y objetivos planteados. De esta manera, demostraremos un correcto funcionamiento del sistema en un ambiente contemplado dentro del alcance de nuestro proyecto.

2.6.2. Escenario

Inicialmente, los integrantes confirmarán que el entorno cumple con los parámetros establecidos: iluminación uniforme, distribución adecuada de productos con suficiente separación entre ellos, y una variedad representativa de las siete categorías de productos soportadas por el sistema.

El procedimiento de validación comprende los siguientes pasos secuenciales:

1. El usuario capturará imágenes del inventario mediante la aplicación móvil desarrollada. Alternativamente, podrá utilizar la cámara nativa del dispositivo y posteriormente importar las fotografías a la aplicación.
2. Tras la captura, el sistema procesará las imágenes utilizando el modelo de visión computacional implementado. La aplicación mostrará al usuario los resultados del análisis, detallando los productos identificados, sus categorías y cantidades.
3. Para garantizar la validez estadística de la evaluación, este proceso se repetirá entre cinco y seis veces bajo condiciones consistentes. Esta metodología iterativa permite obtener una muestra representativa que minimiza la influencia de variables aleatorias en los resultados.
4. Previamente al inicio de las pruebas, se habrá realizado un inventario manual detallado que documentará con precisión las cantidades exactas de productos por categoría presentes en el ambiente de prueba. Este inventario de referencia servirá como parámetro comparativo para evaluar la precisión del sistema.

5. Los resultados de cada iteración se registrarán sistemáticamente, calculando métricas clave como:

- Precisión promedio por categoría
- Tasa de detección global
- Consistencia entre iteraciones
- Incidencia de falsos positivos y falsos negativos

2.6.3. Materiales necesarios

Para esta demostración solamente será necesario contar con un dispositivo móvil que tenga la aplicación de Smart Stock Analyzer instalada en su sistema. Además, se requiere que el backend, la base de datos y el modelo de visión computacional se encuentren desplegados en un Droplet de DigitalOcean que proporcione una dirección IP pública que, a su vez, esté asociada a nuestro nombre de dominio en name.com.

2.6.4. Condiciones de prueba

Para garantizar una demostración óptima de las capacidades del sistema Smart Stock Analyzer, es fundamental crear un entorno de prueba que cumpla con condiciones específicas que maximicen la precisión del reconocimiento visual. Estas condiciones no solo facilitan la validación del sistema durante demostraciones, sino que también representan las mejores prácticas para su implementación en entornos operativos reales.

Iluminación Adecuada

La calidad de la iluminación constituye un factor determinante en la precisión del reconocimiento visual. El sistema requiere un entorno con iluminación uniforme y suficiente, preferiblemente luz natural o artificial de espectro completo, que minimice sombras pronunciadas y reflejos. Se recomienda una intensidad lumínica entre 300-500 lux, evitando tanto condiciones de baja luminosidad como sobreexposición, pues ambas afectan negativamente la capacidad del modelo para identificar características distintivas de los productos. La consistencia en la iluminación entre sesiones de captura también resulta crucial para mantener la coherencia en los resultados del análisis.

Productos Separados

La disposición espacial de los productos influye significativamente en la capacidad del sistema para identificarlos correctamente. Los artículos deben estar visiblemente separados entre sí, manteniendo un espacio mínimo de aproximadamente 1 centímetro entre elementos adyacentes. Esta separación permite que el algoritmo de detección delimite con precisión los contornos de cada producto y evita ambigüedades en la asignación de características a elementos específicos.

Gran Cantidad de Productos

Para validar eficazmente la capacidad del sistema para gestionar inventarios a escala, las demostraciones deben incluir un volumen representativo de productos. Se recomienda un mínimo de 15-50 artículos diversos que abarquen todas las categorías soportadas por el sistema (bebidas, lácteos, cereales, enlatados, galletas/crackers, pastas/fideos y condimentos). Esta variedad permite demostrar la robustez del modelo frente a la diversidad de formas, tamaños, colores y diseños de empaque.

2.6.5. Escenario de respaldo

En el supuesto de que no sea posible acceder a un centro de acopio operativo o instalación equivalente con el volumen y diversidad de productos ideales para la validación, se implementará un escenario de respaldo controlado que permita demostrar las capacidades fundamentales del sistema Smart Stock Analyzer.

Esta alternativa contingente consistirá en la creación de un entorno simulado mediante la recopilación de productos disponibles en los hogares de los integrantes del equipo de desarrollo. Estos artículos se organizarán meticulosamente en un espacio designado, recreando condiciones que emulen la disposición característica de un centro de acopio. Se prestará especial atención a:

- Organizar los productos por categorías, similar a como se encontrarían en un centro real
- Establecer una iluminación uniforme que facilite la captura de imágenes de calidad
- Mantener la separación adecuada entre productos para optimizar la detección

- Incluir una variedad representativa de las siete categorías soportadas por el sistema
- Documentar previamente el inventario exacto para establecer la referencia comparativa

A pesar de las limitaciones inherentes a este escenario artificial, se seguirá rigurosamente el mismo protocolo de validación establecido para el entorno ideal. Se realizarán múltiples iteraciones de captura y análisis, registrando sistemáticamente los resultados para su evaluación comparativa.

Este enfoque de respaldo, aunque no reproduce completamente las condiciones operativas de un centro de acopio a gran escala, permite demostrar eficazmente las capacidades técnicas fundamentales del sistema: la precisión del modelo de visión computacional, la integración funcional entre los componentes, y la experiencia de usuario de la aplicación móvil.

2.7. Análisis y Diseño


2.7.1. Análisis

El estudio del sistema Smart Stock Analyzer se ha organizado a través de varios esquemas que ilustran distintas visiones del flujo de datos y procedimientos del sistema.

El Mapa Conceptual ofrece una panorámica global de los elementos fundamentales del sistema y sus vínculos. Presenta la estructura del sistema en tres subsistemas esenciales: Visión Computacional (responsable de identificar y categorizar productos), Backend (que administra el procesamiento y almacenaje de datos) y Aplicación Móvil (plataforma principal para los usuarios). Estos subsistemas colaboran para ofrecer las características de administración de inventario.

El Diagrama de Procesos muestra el proceso principal de trabajo del sistema, desde la toma de fotografías hasta la creación de alertas y consultas de inventario. Este esquema resalta la manera en que el sistema gestiona diversas situaciones, como la ausencia de conexión a internet o la generación de un inventario base cuando no hay uno anterior.

Los Casos de Uso señalan las relaciones entre los participantes (usuarios, gestores y el sistema en sí) y las capacidades que proporciona el Smart Stock Analyzer. Este esquema establece de manera precisa el ámbito funcional del sistema, ilustrando la manera en que los distintos tipos de usuarios se relacionan con el sistema para llevar a cabo funciones concretas como capturar imágenes, administrar inventarios o establecer centros de recolección.



Mapa Conceptual

Diagrama de Procesos:

El diagrama a continuación ilustra los procesos principales que componen el sistema de Smart Stock Analyzer:




Diagrama de procesos




Diagrama de casos de uso

2.7.2. Diseño

El diseño del sistema detalla la manera en que se aplicarán las funcionalidades detectadas en la etapa de análisis, especificando la estructura interna y los mecanismos particulares del sistema.

Los Mockups preliminares de la aplicación móvil ilustran el diseño de la interfaz de usuario, destacando las pantallas clave que los usuarios usarán: inicio de sesión, tablero principal, captura de imágenes y visualización de los resultados. Estos mockups muestran un diseño intuitivo ajustado a las demandas de los administradores de centros de recolección, poniendo énfasis en la sencillez de manejo y la transparencia en la exposición de datos.

El Diagrama de Clases ilustra la estructura centrada en los objetos del sistema, presentando las entidades fundamentales como el usuario, el centro, la inventariada, la categoría de

producto, la detección e imagen, así como sus atributos, procedimientos y relaciones. Este esquema es esencial para la ejecución del backend del sistema, ofreciendo un modelo definido para la programación basada en objetos en Django.


El Modelo de Datos muestra el esquema relacional de la base de datos PostgreSQL, especificando las tablas, campos y relaciones que facilitan el almacenamiento organizado de todos los datos del sistema. Este modelo asegura la integridad de las referencias y la eficacia en los procesos de consulta de información.

El Diagrama de Despliegue muestra la estructura física del sistema, evidenciando la disposición de los distintos componentes en la infraestructura de Cloud de DigitalOcean. Indica la distinción entre los servidores de aplicación, la base de datos, el almacenamiento y el procesamiento de modelos de aprendizaje automático.

El Diagrama de Secuencia ilustra la relación temporal entre los distintos elementos del sistema durante la captura y análisis de imágenes, resaltando la transmisión de mensajes entre la aplicación móvil, el backend, la base de datos y el modelo de aprendizaje automático.

Diseño de ambiente de usuario (Mockups):

Las siguientes imágenes ilustran el prototipo de momento que se tiene pensado realizar para el proyecto Smart Stock Analyzer.



Pantalla de Captura

[← Atrás](#) **Capturar Inventario**



Posicione la cámara frente a los productos



Recomendaciones:

- Buena iluminación
- Productos separados
- Distancia de 50-120 cm

Pantalla de Resultados

[← Atrás](#) **Resultados**

Productos detectados: 24

$$\begin{array}{r} 400 \\ \times \\ 320 \end{array}$$



Productos Identificados:

Agua embotellada	15
Leche en polvo	4
Galletas	3
Atún enlatado	2




✓ Confirmar

Volver a capturar

Diseño de ambiente de usuario (Mockups):



Diagramas de clase



Modelo de datos




Diagrama de despliegue

Diagrama de secuencia:

bit.ly/4j8Fo4x

Diagrama de secuencia

Análisis de resultados obtenidos en la primera etapa

En el marco de la primera etapa del proyecto, cuya presentación está programada para el 2 de abril de 2025, se ha llevado a cabo una exhaustiva serie de pruebas destinadas a evaluar el comportamiento y la precisión del modelo de visión computacional en diversos escenarios. Este proceso evaluativo ha permitido no solo verificar la efectividad actual del sistema, sino también identificar áreas específicas donde se requieren mejoras sustanciales para la implementación final.

Las pruebas fueron ejecutadas sistemáticamente en entornos controlados, categorizados en dos grupos principales: ambientes con condiciones óptimas, que cumplen con todos los parámetros ideales de iluminación, disposición y variedad de productos; y ambientes con condiciones subóptimas, que simulan las limitaciones frecuentes en centros de acopio reales, como iluminación irregular, oclusión parcial de productos o agrupaciones densas de artículos.

Ambas pruebas fueron realizadas con el siguiente inventario:

- 2 Cherry Star Atún en aceite. Canned Food
- 2 Parmalat Leche Descremada. Dairy
- 1 Goya Adobo Seasoning. Condiments
- 1 Dasani Agua Purificada. Beverage

Condiciones óptimas

Este caso representa pruebas realizadas en escenarios ideales.

- Buena iluminación.
- Correcto posicionamiento de productos.
- Ángulo adecuado para la toma de la imagen.

El objetivo es mostrar el comportamiento del modelo en las mejores condiciones posibles.

# Prueba	Cantidad de objetos	Objetos Identificados	Clasificaciones Correctas	Precisión	Identificación
1	6	3	3	100%	50%
2	6	3	2	66.6%	33%
3	6	1	1	100%	16%
4	6	3	3	100%	50%
5	6	4	2	50%	30%




Imagen de prueba para condiciones óptimas

Condiciones no óptimas

Este caso representa pruebas realizadas en escenarios poco ideales.

- Mala iluminación
- Posicionamiento incorrecto de productos
- Ángulo inadecuado para la toma de imagen

El objetivo es mostrar el comportamiento del modelo en condiciones poco deseables.

# Prueba	Cantidad de objetos	Objetos Identificados	Clasificaciones Correctas	Precisión	Identificación
1	6	4	3	75%	50%
2	6	1	0	0%	0%
3	6	3	0	0%	0%
5	6	2	1	50%	30%
6	6	2	0	0%	30%




Imagen de prueba para condiciones no óptimas

Referencias

- [1] "Identifying Out-of-stock Items at Retail Stores Using Computer Vision: Extended Abstract," *Proceedings of the ACM Symposium on Applied Computing*, 2024, pp. 1067-1068, doi: 10.1145/3605098.3636200.
- [2] "Object Detection in Shelf Image of the Retail store using Single Stage Detector," *2nd IEEE International Conference on Recent Advances in Information Technology for Sustainable Development (ICRAIS 2024) - Proceedings*, 2024, pp. 218-224, doi: 10.1109/ICRAIS62903.2024.10811707.
- [3] "Design and Evaluation of a Real-Time Stock Inventory Management System," *5th IEEE International Conference on Cybernetics, Cognition and Machine Learning Applications (ICCCMLA 2023)*, 2023, pp. 180-185, doi: 10.1109/ICCCMLA58983.2023.10346665.
- [4] B. Balcik and İ. Yanıkoğlu, "A robust optimization approach for humanitarian needs assessment planning under travel time uncertainty," *European Journal of Operational Research*, 2019, doi: 10.1016/j.ejor.2019.09.008.
- [5] L. N. Van Wassenhove, "Sustainable Innovation: Pushing the Boundaries of Traditional Operations Management," *Production and Operations Management*, vol. 28, no. 12, pp. 2930-2945, Dec. 2019, doi: 10.1111/poms.13114.
- [6] M. Çelik, Ö. Ergun, B. Johnson, P. Keskinocak, Á. Lorca, P. Pekgün, and J. Swann, "Humanitarian logistics," in *New directions in informatics, optimization, logistics, and production*, INFORMS, 2012, pp. 18-49.
- [7] L. N. Van Wassenhove, "Humanitarian aid logistics: supply chain management in high gear," *Journal of the Operational Research Society*, vol. 57, no. 5, pp. 475-489, 2006.
- [8] R. M. Tomasini and L. N. Van Wassenhove, "From preparedness to partnerships: case study research on humanitarian logistics," *International Transactions in Operational Research*, vol. 16, no. 5, pp. 549-559, 2009.

- [9] J. Holguín-Veras, M. Jaller, L. N. Van Wassenhove, N. Pérez, and T. Wachtendorf, "On the unique features of post-disaster humanitarian logistics," *Journal of Operations Management*, vol. 30, no. 7-8, pp. 494-506, 2012.
- [10] D. Erlenkotter, "Ford Whitman Harris and the Economic Order Quantity Model," *Operations Research*, vol. 38, no. 6, pp. 937-946, 1990, doi: 10.1287/opre.38.6.937.
- [11] "A novel modeling approach for a capacitated (S,T) inventory system with backlog under stochastic discrete demand and lead time," *International Journal of Production Economics*, 2016.
- [12] I. Z. Karaesmen, A. Scheller-Wolf, and B. Deniz, "Managing Perishable and Aging Inventories: Review and Future Research Directions," in *Planning Production and Inventories in the Extended Enterprise*, Springer, 2011, pp. 393-436, doi: 10.1007/978-1-4419-6485-4_15.
- [13] N. K. Padilla Matute, "Inadecuado manejo de la gestión de inventarios principal causa sobre valoración irreal en las micro empresas de alimentos concentrados," *REDISD*, Aug. 2019.
- [14] G. L. Sanchez-Hernandez, "Optimización de la toma de inventario físico de un almacén de refacciones," *Academia*, 2016.
- [15] R. Szeliski, *Computer Vision: Algorithms and Applications*, 2nd ed. Springer, 2022.
- [16] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)*, San Diego, CA, USA, 2005, pp. 886-893 vol. 1, doi: 10.1109/CVPR.2005.177.
- [17] D. G. Lowe, "Object recognition from local scale-invariant features," *Proceedings of the Seventh IEEE International Conference on Computer Vision*, Kerkyra, Greece, 1999, pp. 1150-1157 vol.2, doi: 10.1109/ICCV.1999.790410.

- [18] H. Bay, A. Ess, T. Tuytelaars, and L. Van Gool, "Speeded-Up Robust Features (SURF)," *Computer Vision and Image Understanding*, vol. 110, no. 3, pp. 346-359, Jun. 2008, doi: 10.1016/j.cviu.2007.09.014.
- [19] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273-297, 1995, doi: 10.1007/BF00994018.
- [20] G. Csurka, C. Dance, L. Fan, J. Willamowski, and C. Bray, "Visual categorization with bags of keypoints," in *Workshop on statistical learning in computer vision, ECCV*, vol. 1, no. 1-22, pp. 1-2, 2004.
- [21] L. Breiman, "Random forests," *Machine Learning*, vol. 45, pp. 5-32, 2001.
- [22] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," *Advances in Neural Information Processing Systems*, vol. 25, 2012.
- [23] R. Girshick, "Fast R-CNN," *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015, pp. 1440-1448.
- [24] W. Liu et al., "SSD: Single Shot MultiBox Detector," in *Computer Vision – ECCV 2016*, Lecture Notes in Computer Science, vol. 9905, Springer, 2016, doi: 10.1007/978-3-319-46448-0_2.
- [25] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779-788.
- [26] Y. Cai, L. Wen, L. Zhang, D. Du, and W. Wang, "Rethinking Object Detection in Retail Stores," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 2, pp. 947-954, 2021, doi: 10.1609/aaai.v35i2.16178.
- [27] M. Yin, X. Jia, J. Feng, and Y. Qiao, "Computer vision-based quantity detection of goods in vending cabinets," *2022 China Automation Congress (CAC)*, Xiamen, China, 2022, pp. 666-671, doi: 10.1109/CAC57257.2022.10055606.

- [28] P. Jain, P. Chawla, M. Masud, S. Mahajan, and A. K. Pandit, "Automated Identification Algorithm Using CNN for Computer Vision in Smart Refrigerators," *Computers, Materials & Continua*, vol. 71, no. 2, 2022.
- [29] Ultralytics Team, "De las estanterías a las ventas: Explorando Ultralytics YOLOv8's Impacto en la Gestión de Inventarios," Ultralytics Blog, Jun. 2023.
- [30] K. C. Laudon and J. P. Laudon, *Sistemas de informação gerenciais: administrando a empresa digital*, Bookman Editora, 2022.
- [31] A. Howard et al., "Searching for MobileNetV3," *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, Seoul, Korea (South), 2019, pp. 1314-1324, doi: 10.1109/ICCV.2019.00140.
- [32] "Trax Retail," [Online]. Available: <https://traxretail.com/>
- [33] "Shelfie Pro Retail Recognition Robot," [Online]. Available: <https://www.shelfiepro.be/en/shelfie-pro-retail-recognition-robot/>
- [34] "Count It - Inventory Management App," [Online]. Available: <https://play.google.com/store/apps/details?hl=es&id=com.visualogyx.countit.app>
- [35] "ShelfWatch - ParallelDots," [Online]. Available: <https://www.paralleldots.com/shelfwatch>
- [36] B. Varghese and R. Buyya, "Next generation cloud computing: New trends and research directions," *Future Generation Computer Systems*, vol. 79, pp. 849-861, 2018.
- [37] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, "Edge Computing: Vision and Challenges," *IEEE Internet of Things Journal*, vol. 3, no. 5, pp. 637-646, Oct. 2016, doi: 10.1109/JIOT.2016.2579198.